



UNIVERSIDAD MAYOR DE SAN SIMÓN
FACULTAD DE CIENCIAS Y TECNOLOGÍA



DIRECCIÓN DE POSGRADO

**DIPLOMADO ESTADÍSTICA APLICADA A LA
TOMA DE DECISIONES
TERCERA VERSIÓN**

**MODELO DE MACHINE LEARNING PARA LA
CLASIFICACIÓN DE DEFAULT DE CREDITOS EN
LA COOPERATIVA “CACEF”**

**PROYECTO PRESENTADO PARA OBTENER EL GRADO DE LICENCIATURA EN
INGENIERÍA INDUSTRIAL
MODALIDAD DOBLE TITULACIÓN**

POSTULANTE : NEIL IVER INCLAN PIÉROLA

TUTOR : M. Sc. Ing. DANNY HUANCA SEVILLA

Cochabamba – Bolivia

2025

MODELO DE MACHINE LEARNING PARA LA CLASIFICACIÓN DE DEFAULT DE CRÉDITOS EN LA COOPERATIVA “CACEF”

Por

Neil Iver Inclan Piérola

El presente documento, Trabajo de Grado es presentado a la Dirección de Posgrado de la Facultad de Ciencias y Tecnología en cumplimiento parcial de los requisitos para la obtención del grado académico de Licenciatura en Ingeniería Industrial, modalidad Doble Titulación, habiendo cursado el Diplomado “Estadística Aplicada a la Toma de Decisiones” propuesta por el Centro de Estadística Aplicada (CESA) en su tercera versión.

ASESOR/TUTOR

M. Sc. Ing. Danny Huanca Sevilla

COMITÉ DE EVALUACIÓN

Ing. M.Sc. Ronald Edgar Patiño Tito. (Presidente)

Ing. M.Sc Guillen Salvador Roxana,. (Coordinador)

Ing. M.Sc Oscar Contreras Carrasco (Tribunal)

Ing. M.Sc Wilson Trujillo Aranibar (Tribunal)



DIRECCIÓN DE POSGRADO, FACULTAD DE CIENCIAS Y TECNOLOGIA

Cochabamba, Bolivia

Aclaración

Este documento describe el trabajo realizado como parte del programa de estudios de Diplomado “Estadística Aplicada a la Toma de Decisiones” en el Centro de Estadística Aplicada CESA y la Dirección de Posgrado de la Facultad de Ciencias y Tecnología. Todos los puntos de vista y opiniones expresadas en el mismo son responsabilidad exclusiva del autor y no representan necesariamente las de la institución.

Resumen

El presente proyecto desarrolla un modelo de Machine Learning para clasificar si un crédito otorgado por la cooperativa “CACEF” caerá en default o no, utilizando características financieras del crédito y el comportamiento histórico de los clientes. Siguiendo la metodología CRISP-DM, se realizó un análisis exploratorio de datos para identificar patrones y distribuciones relevantes, seguido de una preparación del conjunto de datos para el entrenamiento de los modelos. Se aplicaron técnicas de balanceo como SMOTE y transformaciones en las variables numéricas para mejorar la calidad de los datos.

Los modelos de clasificación entrenados fueron, la red neuronal profunda (DNN) obtuvo el mejor rendimiento con un recall de 55.6% y una precisión del 40%, mientras que la regresión logística alcanzó un recall del 39% y una precisión del 5%, seguidos del modelo Random Forest con 33% de Recall y 2.4% de Precisión, finalmente se tiene al modelo XGBoost con 5.6% de Recall y 2.6% de Precisión. Estos resultados reflejan el impacto del desbalance en los datos, aunque muestran una mejora en la detección de casos de default en comparación con el modelo actual de la cooperativa.

Los hallazgos indican que variables como la tasa de interés, la duración del crédito y el monto diferido tienen una alta influencia en la predicción del incumplimiento. Sin embargo, la calidad de los datos fue un desafío, ya que muchas variables presentaron valores sesgados o incompletos, particularmente en ingresos y gastos de los clientes.

En conclusión, los modelos desarrollados representan una mejora en la detección de créditos en riesgo, aunque persisten limitaciones debido a la calidad y el desbalance de los datos. Los resultados sugieren la necesidad de optimizar la recolección de información financiera de los clientes para mejorar la capacidad predictiva de futuros modelos.

Palabras clave

Modelo de clasificación, Red Neuronal Artificial, Default de créditos, Gestión del riesgo crediticio, Riesgo crediticio

Dedico este trabajo con todo mi cariño a mi familia y amigos, por estar siempre presentes con su apoyo incondicional, sus palabras de aliento y su compañía en cada paso del camino.

A mi Camille, quién me recuerda por qué todo esfuerzo vale la pena y a mi querido abuelo Javier, que sigue presente con su sabiduría, su fe en mí, recordándome siempre que todo es posible cuando se camina con amor y convicción.

Agradecimientos

Al Ing. Danny Huanca Sevilla, por su valiosa orientación como tutor de este trabajo, por su disposición permanente, sus observaciones oportunas y por el acompañamiento comprometido que contribuyó significativamente al desarrollo de este proyecto.

Al equipo académico del Diplomado, por la formación rigurosa brindada, la calidad de los contenidos impartidos y por fomentar un espacio de aprendizaje enriquecedor, que ha sido clave en mi proceso formativo.

A la Cooperativa CACEF, por su generosa disposición institucional, el apoyo brindado para la ejecución de esta investigación y por permitir el acceso a información clave para su desarrollo.

Y de manera especial, al equipo de sistemas de CACEF, por su colaboración técnica y por facilitarme de manera eficiente y oportuna los datos requeridos, sin los cuales este trabajo no habría sido posible

.

Tabla de contenidos

Contenido

1.	Introducción	1
1.1.	Antecedentes	1
1.2.	Justificación	2
1.3.	Planteamiento del problema	3
1.4.	Objetivo general.....	3
1.4.1.	Objetivos específicos	3
2.	Marco teórico	4
2.1.	Machine Learning	4
2.1.1.	Clasificación de los modelos de Machine Learning.....	4
2.1.2.	Modelos de aprendizaje supervisado para clasificación	5
2.1.3.	Deep Learning y Redes Neuronales Artificiales.....	7
2.1.4.	Principales desafíos del Machine Learning	7
2.2.	Evaluación del desempeño de modelos de Machine Learning.....	8
2.2.1.	Métricas para modelos de regresión.....	8
2.2.2.	Métricas para modelos de clasificación.....	8
2.3.	Metodología CRISP-DM.....	10
2.4.	Tendencias tecnológicas en la banca	11
2.5.	Gestión del riesgo crediticio	11
2.5.1.	Riesgo crediticio.....	12
2.6.	Evaluación del riesgo crediticio	12
2.6.1.	Proceso tradicional de la evaluación de créditos.....	13
2.6.2.	Estimación del default de créditos	14
3.	Marco metodológico	15
3.1.	Área de estudio	15
3.2.	Flujograma metodológico	16
3.3.	Fuentes de información.....	17
3.3.1.	Fuente de información secundaria	17
3.4.	Adquisición y análisis exploratorio de datos.....	17

3.4.1.	Adquisición de los datos	17
3.4.2.	Estructura y características de los datos	17
3.4.3.	Exploración inicial.....	19
3.4.4.	Análisis univariado	19
3.4.5.	Análisis bivariado.....	22
3.4.6.	Análisis de correlación	24
3.4.7.	Análisis de asociación	24
3.5.	Preparación de los datos.....	25
3.5.1.	Eliminación de variables.....	25
3.5.2.	Tratamiento de valores nulos	26
3.5.3.	Combinación de variables	26
3.5.4.	Agrupación de clases.....	27
3.5.5.	Tratamiento a valores atípicos.....	27
3.5.6.	One-Hot Encoding	28
3.6.	Entrenamiento de modelos.....	28
3.6.1.	Separación de Conjunto de entrenamiento y evaluación.....	28
3.6.2.	Técnicas de balanceo de clases.....	29
3.6.3.	Entrenamiento del modelo de Regresión Logística	29
3.6.4.	Entrenamiento del modelo Random Forest.....	31
3.6.5.	Entrenamiento del modelo XGBoost.....	31
3.6.6.	Entrenamiento del modelo Red Neuronal Profunda.....	32
3.7.	Evaluación y selección de los modelos	34
3.7.1.	Estrategia de validación.....	34
3.7.2.	Criterios de evaluación	34
3.7.3.	Selección de los modelos.....	36
4.	Análisis de los resultados y discusión.....	37
4.1.	Análisis de los resultados del análisis exploratorio de datos	37
4.2.	Análisis de los resultados de la preparación de datos.....	48
4.3.	Análisis de los resultados del entrenamiento de los modelos	48
4.3.1.	Hiperparámetros optimizados para la regresión logística.....	48
4.3.2.	Hiperparámetros optimizados para XGBoost	48
4.3.3.	Hiperparámetros optimizados del árbol aleatorio	49

4.3.4.	Hiperparámetros optimizados de la red neuronal profunda.....	49
4.4.	Análisis de los resultados de la evaluación de los modelos	50
4.4.1.	Selección de los modelos.....	53
4.5.	Discusión de los resultados.....	53
5.	Conclusiones.....	56
6.	Recomendaciones	57
	Referencias bibliográficas	58
	Anexos.....	60
	Anexo 1 Vista previa del conjunto de datos	60
	Anexo 2 Función de análisis univariado variables numéricas	61
	Anexo 3 Función de análisis univariado variables categóricas.....	62
	Anexo 4 Función de análisis bivariado variables numéricas	63
	Anexo 5 Función de análisis bivariado variables categóricas	64
	Anexo 6 QR del repositorio Github.....	65
	Anexo principal y distribución de carpetas del CD	66

Lista de figuras

Figura 2-1 Representación de un árbol de decisión	6
Figura 2-2 Ejemplo de la curva ROC	10
Figura 3-1 Área de Estudio, Cochabamba Bolivia	15
Figura 3-2 Flujograma Metodológico	16
Figura 3-3 Histogramas y diagramas de caja de variables del cliente.....	20
Figura 3-4 Gráfica de conteo para variables de cliente.....	21
Figura 3-5 Análisis bivariado de variables numéricas de cliente	22
Figura 3-6 Análisis bivariado de variables categóricas de cliente.....	23
Figura 4-1 Análisis univariado de departamento	38
Figura 4-2 Cantidad de créditos otorgados y monto promedio desembolsado por semestre	38
Figura 4-3 Histograma y diagrama de cajas para variables de crédito, parte 1	39
Figura 4-4 Histograma y diagrama de cajas para variables de crédito, parte 2	40
Figura 4-5 Histograma y diagrama de cajas para variables de crédito, parte 1	41
Figura 4-6 Gráficos de barra de variables de crédito	42
Figura 4-7 Análisis bivariado de variables de crédito, parte 2	43
Figura 4-8 Análisis bivariado de variables de crédito, parte 3	44
Figura 4-9 Análisis bivariado de variables categóricas de crédito.....	45
Figura 4-10 Matriz de correlación.....	46
Figura 4-11 Matriz de asociación	47
Figura 4-12 Segas antes y después de las transformaciones	48
Figura 4-13 Evaluación del modelo de Regresión Logística	50
Figura 4-14 Evaluación de modelos Bosque Aleatorio y XGBoost	51
Figura 4-15 Evaluación de la Red Neuronal Profunda	52
Figura 4-16 Matriz de confusión del modelo de Red Neuronal.....	53
Figura 4-17 Matriz de confusión del modelo de XGBoost.....	54
Figura 4-18 Curvas ROC de los modelos entrenados	55

Lista de tablas

Tabla 2-1 Ejemplo de Matriz de Confusión 9

Tabla 3-1 Estructura de los datos de “CACEF”. 19

Tabla 3-2 Ejemplo de Tabla de Resultados 36

Tabla 4-1 Resumen de resultados de la evaluación y selección de modelos 53

Tabla 4-2 Métricas de Evaluación de los modelos 55

1. Introducción

La evaluación crediticia es una de las actividades más importantes de las empresas del sector financiero (O'Brien & Downie, 2024), tener la capacidad de predecir si un cliente será capaz de cumplir con sus obligaciones financieras es fundamental para reducir el riesgo crediticio, así como para el funcionamiento eficiente de una economía moderna (Yhip & Alagheband, 2020). En general, estos procesos se realizan a través de un análisis para cada caso o cliente, con el apoyo de modelos actuariales que permiten estimar el riesgo de cada solicitud, así como otros criterios subjetivos, los cuales pueden causar decisiones sesgadas, ser ineficientes o volverse obsoletos al no considerar nuevas tendencias y factores del mercado (Carlone, 2020).

En la actualidad, gracias a la disponibilidad de grandes volúmenes de datos y a los avances en la Inteligencia artificial, como ser el Machine learning, las entidades financieras han estado acercándose más a implementar soluciones que al aprovechar estas fuentes de datos permiten mejorar varios aspectos del modelado del riesgo crediticio (Locatelli, Pepe, & Salis, 2022). Estos modelos permiten agilizar y personalizar el proceso de evaluación crediticia, mejorando la eficiencia y reduciendo el riesgo para las instituciones financieras (O'Brien & Downie, 2024).

Los beneficios de la introducción de la I.A. en empresas financieras son muy variados, algunos ejemplos que sobrepasan las expectativas de los clientes incluyen, servicios predictivos para anticipar necesidades de los clientes, que pueden ser ayudar a los clientes a resolver problemas comunes de sus cuentas de banco, proveer asesoramiento financiero personalizado, aumentar la seguridad de los activos financieros de los clientes detectando y previniendo fraudes (Leleko & Chupryna, 2024).

Este proyecto propone desarrollar un modelo de Machine learning que permita clasificar si un crédito otorgado caerá en default o no, basándose en variables como su historial crediticio, ingresos y otros factores relevantes que tenga disponibles la cooperativa, logrando así tener una estimación más oportuna del default, mejorando la calidad de atención de los clientes de la cooperativa.

1.1. Antecedentes

La práctica de solicitar y realizar préstamos, tiene raíces en culturas de hace varios milenios atrás, un ejemplo importante de la antigüedad sucedió en los templos de Mesopotamia que poco a poco empezaron a utilizarse como bancos, creando el primer sistema de créditos con reglas y condiciones e introduciendo el concepto de “interés” que luego fueron parte de legislación escrita en el código de Hammurabi. (Singh, 2024). En la antigua Roma, se realizaban préstamos a corto o mediano plazo, debido a las fatales consecuencias de incumplir con la devolución de una deuda, esto cambió con la introducción de nuevas leyes que permitieron a los deudores pagar con sus bienes en caso de incumplir sus obligaciones

con el acreedor, lo que cambió el enfoque de los acreedores para seleccionar y asignar préstamos a personas con bienes más valiosos. (Kenneth, 1984).

Desde el siglo XIX se ha utilizado el score crediticio para apoyarse en la aprobación o rechazo de una solicitud de préstamo, las primeras apariciones del score crediticio en Estados Unidos mencionan que se usaban por mercaderes para estimar la confiabilidad de sus clientes potenciales, y no fue hasta 1960 que esta información se computarizó para poder realizar reportes de forma eficiente, luego la empresa FICO se encargaba de calcular individualmente los scores crediticios a pedido para diferentes empresas, y en 1989 estandarizaron por primera vez el cálculo del score crediticio, el cual fue actualizado y refinado hasta la actualidad, hoy en día existen varios modelos para calcular este parámetro, pero según FICO su modelo es usado por el 90% de los prestamistas más importantes en Estados Unidos. (Paul, 2024).

En la actualidad la industria financiera está aprovechando a tecnologías emergentes, como ser el Machine Learning, las compañías líderes de este sector no solo han adoptado su concepto, sino que continuamente buscan optimizar sus iniciativas de Inteligencia Artificial, algunos de los usos más destacados van desde mejorar la atención al cliente, la detección de fraudes, hasta la creación de soluciones para la gestión de riesgos. (Leleko & Chupryna, 2024). El Machine Learning es parte de la Inteligencia Artificial, con un enfoque a realizar tareas específicas, resulta excelente en el descubrimiento de patrones, esto permite hacer predicciones y recomendaciones confiables, todo esto gracias al procesamiento de grandes volúmenes de datos. (BBVA, 2024).

La adopción del Machine Learning en el sector financiero se ha convertido en una tendencia moderna, es utilizado ampliamente en la gestión de riesgos, más específicamente en la gestión de riesgos de crédito, los cuales suelen ser los más críticos para este sector, esta tecnología ha demostrado tener ventajas de rendimiento sobre otros métodos tradicionales. (Hermitaño Castro, 2022). En cuanto a los modelos o algoritmos más utilizados en diferentes artículos se encontró que un 68% se utilizan para tareas como la clasificación de créditos, 47% para la regresión de variables y 21% para la agrupación de clientes, entre otros, donde sobresalen los siguientes modelos Redes Neuronales Convolucionales (CNN), Regresión logística (LR), arboles de decisiones (DT) que se usaron en un 32% de los estudios, también se evidencia el uso de Support Vector Machine (SVM) y finalmente K-Nearest Neighbors (KNN) que se usaron en un 26% y 21% de los estudios respectivamente. (Solano Padilla & Quimi Andrade, 2024).

1.2. Justificación

La cooperativa “CACEF” busca impulsar el desarrollo económico y social tanto de sus socios como de la comunidad en general a través de prestar servicios financieros responsables y eficientes, conectando ahorradores y prestatarios, promoviendo su crecimiento sostenible, con el fin de consolidarse como una cooperativa líder en Cochabamba (Cooperativa CACEF R.L., 2025). Debido a la alta competitividad del sector financiero, las instituciones bancarias deben tomar decisiones más rápido y de forma más precisa, en este caso, acerca de la aprobación de créditos para minimizar las pérdidas y maximizar la rentabilidad.

Actualmente en la cooperativa “CACEF”, el proceso de evaluación crediticia se realiza individualmente para cada crédito revisando criterios tradicionales, apoyada en el cálculo y uso de un modelo propio de

la cooperativa que está basado en otros modelos econométricos y se ha desarrollado en hojas de cálculo, los cuales pueden resultar ser ineficientes a medida que la institución crece, aumentando así el riesgo de incurrir en pérdidas, además de disminuir su competitividad en el mercado.

1.3. Planteamiento del problema

Actualmente, el proceso de asignación de créditos en la cooperativa “CACEF” está basado principalmente en el criterio de los agentes de crédito que se apoyan en un modelo interno propio de la empresa que considera variables como el historial crediticio, variables demográficas y otros factores clave, las cuales permiten estimar un puntaje crediticio de cada caso, utilizando softwares de hojas de cálculo, principalmente Excel, por razones de confidencialidad no se mencionará el método exacto. Este modelo ha demostrado ser útil en años anteriores, pero se han encontrado limitaciones para adaptarse a nuevas tendencias del mercado y se han registrado resultados inconsistentes al momento de evaluar individualmente las solicitudes de crédito.

Esta situación representa una oportunidad de mejora importante para la clasificación de créditos de la cooperativa, en este contexto, se propone desarrollar un modelo de clasificación utilizando técnicas de machine learning. Esta iniciativa pretende mejorar la consistencia de la identificación del default de créditos, impactando indirectamente otras tareas del proceso de otorgación de créditos, como ser la asignación de la tasa de interés, lo que afectaría positivamente a la satisfacción del cliente. Además, que esta alternativa de desarrollar modelos de Machine learning, permite ajustarse a las nuevas condiciones del mercado, y así lograr obtener una herramienta versátil capaz de apoyar oportunamente la toma de decisiones de los oficiales de créditos.

1.4. Objetivo general

Desarrollar un modelo de Machine learning para la clasificación de default de créditos de la cooperativa “CACEF”.

1.4.1. Objetivos específicos

- Adquirir datos de los créditos de la cooperativa para realizar un análisis exploratorio que permita conocer patrones, distribuciones y otras estadísticas del conjunto de datos.
- Preparar el conjunto de datos para la creación de la tabla minable.
- Entrenar modelos de machine learning, encontrando los mejores hiperparámetros para cada modelo.
- Evaluar los modelos utilizando métricas, como ser la Precisión, Recall, ROC-AUC, PR-AUC para seleccionar el mejor.

2. Marco teórico

2.1. Machine Learning

El Machine learning es un paradigma de la computación, que permite que las computadoras aprendan de los datos para resolver problemas, sin la intervención explícita de las personas, es decir, es darle la habilidad de encontrar patrones y relaciones entre los datos, a diferencia de los algoritmos clásicos que consistían en que una persona encuentre la mejor solución posible a un problema para luego traducirlo a código e indicar directamente que debe hacer la computadora, ahora la computadora aprende de ejemplos de los problemas para poder encontrar la mejor solución por su cuenta (Ozdemir, 2024).

El propósito que tiene el Machine learning es predecir y analizar datos, lo que permite reducir la incertidumbre de los nuevos datos que se generen. Esta tecnología logra estas tareas a través de la construcción y aplicación de modelos probabilísticos y estadísticos, que se pueden optimizar para el mejor aprendizaje del modelo para que luego analice y posteriormente pueda realizar predicciones precisas (Li, 2019).

Su importancia radica en la capacidad para resolver problemas que son muy complejos para los métodos tradicionales, problemas para los que no se ha desarrollado un algoritmo eficiente, y también en descubrir patrones ocultos y nuevas tendencias en grandes volúmenes de datos, dónde la responsabilidad del desarrollador se centra en optimizar el rendimiento del modelo preparando los datos que se tengan disponibles, e intentando minimizar los errores y sesgos del proceso (Géron, 2023).

2.1.1. Clasificación de los modelos de Machine Learning

De acuerdo con (Hurbans, 2020) , los modelos de Machine learning tienen enfoques específicos para realizar ciertas tareas que podrían presentarse en una gran variedad de áreas de estudio, entonces una manera tradicional y general de clasificarlos es la siguiente:

- Aprendizaje Supervisado, es una de las técnicas más conocida del Machine learning tradicional, logra descubrir los patrones de datos etiquetados, es decir, que cuentan con una variable objetivo para luego realizar predicciones de esta variable objetivo de nuevos ejemplos o casos, es decir, es necesario alimentar al modelo con las variables explicativas y una o más variables objetivo, de manera que la computadora tenga las respuestas correctas de cada caso y pueda encontrar los patrones para estimar esas respuestas correctas en nuevos casos. Tiene dos subcategorías importantes que son:
 - Regresión, se utiliza para predecir valores numéricos, en otras palabras, encontrar una función que pueda estimar mediante la identificación de relaciones entre variables, por

ejemplo, el precio de un inmueble, el consumo de energía eléctrica de una fábrica, la demanda de un producto, etc. Permite conocer también la relación o el peso que tiene cada variable con la variable objetivo.

- Clasificación, tiene por objetivo predecir la categoría a la que pertenece un nuevo caso, por ejemplo, si fuese una clasificación binaria como determinar si una transacción es fraudulenta o no, identificar productos defectuosos en una fábrica, o en este caso la evaluación del riesgo crediticio (Aceptar o rechazar).
- Aprendizaje no Supervisado, no necesita de ninguna variable objetivo, se concentra en hallar tendencias y patrones en los datos que no se pueden hallar manualmente, sirve como una herramienta de análisis profundo, que consiste en dejar que la computadora encuentre esos patrones por su cuenta y después analizar los resultados para entender su razonamiento. Permite realizar muchas tareas de análisis y reducción de complejidad en los conjuntos de datos, una de las más conocidas es el Clustering o agrupación de datos, por ejemplo, de clientes con características similares que no se pueden identificar a simple vista.

2.1.2. Modelos de aprendizaje supervisado para clasificación

- **Regresión logística**, es una extensión de la regresión lineal, que transforma las salidas a un intervalo entre 0 y 1 mediante la función sigmoide o logística, véase Ecuación 2-1, es decir, predice la probabilidad de que dadas las variables explicativas el caso pertenezca a una clase u otra, para problemas de clasificación binaria generalmente establece el umbral de decisión en 0.5, si el resultado de la función resulta en un valor mayor o igual a este umbral lo clasifica como verdadero, de otro modo como falso (Lau, Gonzalez, & Nolan, 2023).

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$

Ecuación 2-1 Función sigmoide

Fuente: Lau, Gonzales & Nolan, 2023

- **Árbol de decisión**, es un modelo basado en una estructura jerárquica que permite la clasificación en función a los atributos, se compone de nodos y aristas, donde los nodos principales son los nodos internos, que representan una característica o atributo de los datos y los nodos hoja, que representan la clase o categoría a la cual el modelo determina que pertenece un caso. La manera en la que funcionan es la siguiente, todo parte desde el nodo raíz, donde se evalúa una característica del dato de entrada, resultado de esto el caso pasa a un nodo hijo donde se evalúa

otra característica, esto sucede recursivamente hasta alcanzar un nodo hoja en el que el caso queda clasificado (Li, 2019). Se puede representar como la Figura 2-1:




Figura 2-1 Representación de un árbol de decisión

Fuente: Li, 2019

Modelos combinados, es una técnica que consiste en combinar múltiples modelos de Machine learning para incrementar el rendimiento de las predicciones, se basa en la “sabiduría de la multitud”, suele aplicarse al final del desarrollo de los modelos una vez fueron entrenados, y así obtener un modelo más robusto tras ser combinados. Algunos de los métodos de combinación más populares son los siguientes:

- **Clasificadores por votación**, es una de las maneras más sencillas de combinar clasificadores, consiste en contar como votos el resultado de la clasificación de varios modelos y dar como resultado la clase más votada.
- **Bagging (Bootstrap aggregating) y Pasting**, consiste en entrenar en paralelo a varios modelos en diferentes muestras de los datos de entrenamiento, cada modelo entrena de forma independiente en su subconjunto y como resultado se obtiene la moda o clase más frecuente, la diferencia entre el Bagging y el Pasting, es que el primero utiliza muestreo con reemplazo y el segundo no. Un ejemplo de Bagging es el **Bosque Aleatorio o Random Forest**, que entrena a varios árboles de decisión, se dicen aleatorios porque cada árbol usa un subconjunto aleatorio de las variables explicativas, lo que permite reducir la correlación entre los árboles.
- **Boosting**, consiste en entrenar modelos secuencialmente con la idea de que el modelo siguiente corregirá al modelo anterior. Existen varios métodos dentro de esta categoría como ser el **AdaBoost (Adaptive Boosting)**, asigna pesos a cada caso del conjunto de entrenamiento y los ajusta para que en cada iteración el modelo siguiente preste más atención a los casos que

fueron clasificados erróneamente. **Gradient Boosting**, a diferencia del AdaBoost, esta técnica entrena a cada modelo nuevo en base a los errores residuales del modelo anterior. (Géron, 2023)

2.1.3. Deep Learning y Redes Neuronales Artificiales

El Deep Learning es una rama del Machine learning, que emplea modelos más sofisticados y complejos, en su mayoría redes neuronales artificiales (RNA), a diferencia de los modelos tradicionales del Machine learning, las redes neuronales tienen una mayor capacidad para modelar relaciones no lineales complejas entre múltiples variables, esto las hace un recurso muy valioso para tareas como el reconocimiento de imágenes, el procesamiento de lenguaje natural y predicción de series temporales, aparte de poder resolver los mismos problemas que los modelos tradicionales (Kaabar, 2024).

Las redes neuronales artificiales (RNA), están inspiradas en el funcionamiento de las neuronas biológicas del cerebro. Su arquitectura se organiza en tres tipos de capas, la capa de entrada, las capas ocultas y la capa de salida o de resultado, cuando una RNA contiene múltiples capas ocultas, se llama red neuronal profunda (Deep Neural Network, DNN), que son las que constituyen la base del Deep learning (Géron, 2023).

El proceso de aprendizaje de una RNA inicia en la capa de entrada, dónde se reciben los datos de entrada y la dimensión matricial de las variables explicativas, sean cuantitativas o cualitativas, que ahora se pueden aplanar como un vector. Posteriormente, al pasar a las capas ocultas, se procesan los datos entre las conexiones de las neuronas, cada una realiza algún cálculo según la función de activación que se haya escogido y da un peso a los resultados de las neuronas para luego pasar su resultado a las siguientes capas ocultas, finalmente la capa de resultado traduce la información procesada en las capas ocultas para generar la predicción de la o las variables de salida (Kaabar, 2024).

2.1.4. Principales desafíos del Machine Learning

Los modelos de Machine learning no son perfectos, ya que su desempeño depende en gran medida de la calidad de los datos de entrada, para dar resultados que valgan la pena analizar e implementar (Ozdemir, 2024). De acuerdo con (Géron, 2023), los dos factores que pueden causar errores en el proceso de encontrar soluciones con Machine learning son escoger o aplicar un mal modelo o tener “malos datos”, algunos de los principales desafíos incluyen:

- Datos insuficientes, los modelos de machine learning necesitan de una gran cantidad de datos, de ejemplos, para poder encontrar soluciones correctamente, dependiendo la complejidad del problema, mientras más difícil más datos se necesitarán. También es necesario mencionar que los datos deben ser representativos de todos los casos que se consideran relevantes para la variable objetivo, una posible solución es aumentar la cantidad de ejemplos.
- Datos de baja calidad, habla de los errores, el ruido y los casos atípicos que ocurren durante la recolección y almacenamiento de datos, reducen el desempeño del modelo al hacer más difícil el reconocimiento de patrones, para resolver esto se realiza limpieza y organización de los datos de entrenamiento.

- Variables irrelevantes, las variables que no añaden valor al modelo generan ruido en el aprendizaje, por lo que se tienen que reducir, para esto se utiliza un proceso llamado “Feature Engineering” que consiste en seleccionar las variables más importantes, combinar las variables existentes para aumentar su relevancia y/o crear nuevas variables recolectando nuevos datos.
- Overfitting o sobreajuste del modelo, ocurre cuando el modelo es demasiado complejo y la cantidad de datos es muy pequeña o tiene mucho ruido, por lo que aprende patrones que no son relevantes para el resultado final, lo que causa errores en la generalización. Para esto se puede crear restricciones al modelo, reducir las variables, o probar modelos de menor complejidad.
- Underfitting o subajuste, es lo contrario al overfitting, ocurre cuando el modelo es muy simple y no logra captar todas las relaciones y patrones en los datos, se puede mejorar escogiendo un modelo más complejo o reduciendo las restricciones impuestas al modelo.

2.2. Evaluación del desempeño de modelos de Machine Learning

Una vez ajustado y entrenado el modelo, es fundamental evaluar su desempeño para garantizar que cumple con los requerimientos de la empresa y para identificar oportunidades de mejora (McMahon, 2023), se debe medir el desempeño del modelo en este caso para modelos de aprendizaje supervisado mediante métricas como las que se verán a continuación.

2.2.1. Métricas para modelos de regresión

Según (Ozdemir, 2024), existen tres métricas esenciales para evaluar modelos de regresión, de las cuales se puede usar una o varias al mismo tiempo, son:

- **Error absoluto medio o MAE** (Mean Absolute Error), es el promedio de los errores absolutos que son la diferencia entre los valores reales y los valores predichos por el modelo, es una medida directa del error que comete el modelo.
- **Error cuadrático medio o MSE** (Mean Squared Error), se trata del promedio de los errores elevados al cuadrado, es útil para penalizar la amplitud de los errores que produce el modelo.
- **Raíz del error cuadrático medio o RMSE** (Root Mean Squared Error), se obtiene extrayendo la raíz cuadrática del error cuadrático medio, que se explicó antes, es importante porque logra ser más interpretable al escalar la medida a las unidades originales de la variable manteniendo su sensibilidad a la amplitud de los errores del modelo.
-

2.2.2. Métricas para modelos de clasificación

Para los problemas de clasificación puede que una sola métrica no logre medir el desempeño de un modelo, por ejemplo, si se toma únicamente a la exactitud (Accuracy), que es la proporción de predicciones correctas del total de predicciones, y se crea un modelo que aprenda a optimizar para esta métrica podría llegar a grandes errores si el conjunto de datos es desbalanceado, es decir, que la variable que se quiere predecir ocurre muy pocas veces, por lo que el modelo simplemente aprende a clasificar a

la mayoría de los casos nuevos directamente como la clase más común. (Lau, Gonzalez, & Nolan, 2023). Es por esto que la exactitud en general, no es la mejor métrica de desempeño para modelos clasificadores, ya que lo que se requiere es poder diferenciar entre los tipos de clasificación correctos e incorrectos, en especial para conjuntos de datos contienen a algunas clases mucho más frecuentemente que otras (Géron, 2023). Según (Lau, Gonzalez, & Nolan, 2023) la matriz de confusión, es una herramienta para verificar los errores y aciertos de las predicciones del modelo, para un modelo de clasificación binaria, la matriz de confusión compara los valores obtenidos para **Falsos positivos**, son los que el modelo clasifica como 1 pero en realidad son 0, **Falsos negativos**, al contrario, se clasifican como 0 pero en realidad son 1, ver Tabla 2-1:

		Valor Predicho	
		Falso (0)	Verdadero (1)
Valor Real	Falso (0)	Verdaderos negativos	Falsos positivos
	Verdadero (1)	Falsos negativos	Verdaderos positivos

Tabla 2-1 Ejemplo de Matriz de Confusión

Fuente: Elaboración propia, 2025

El modelo muestra mejor rendimiento si la diagonal principal acumula los valores más altos, es decir, se clasifica correctamente tanto los Verdaderos negativos y los Verdaderos Positivos, pero para hacer una revisión más profunda es mejor calcular proporciones derivadas de esta matriz (Géron, 2023). La **Precisión**, se define como la proporción de Verdaderos positivos entre el Total de positivos predichos por el modelo, tener una precisión alta significa que el modelo es capaz de predecir de manera confiable a los casos que en verdad son positivos (Lau, Gonzalez, & Nolan, 2023).

El **Recall** o **sensibilidad**, es la proporción de Verdaderos positivos entre el Total de positivos reales del conjunto de datos, optimizar esta métrica significa que el modelo es eficaz distinguiendo a los casos reales que existen en los datos. Es necesario determinar cuál de las dos métricas es más importante para cada modelo, ya que, usualmente si aumenta una la otra baja (Géron, 2023). Finalmente se puede medir el **F1 Score** que es el promedio armónico de las dos métricas mencionadas antes, si tiene un valor alto significa que el modelo tiene un buen desempeño en ambas métricas (Ozdemir, 2024).

La **curva de Receiver Operating Characteristic o ROC**, por sus siglas en inglés, es otra herramienta común para visualizar el desempeño de modelos de clasificación, consiste en graficar el Recall y la proporción de falsos negativos (false positive rate, FPR), véase Figura 2-2, casos identificados erróneamente como positivos. Otra métrica derivada del ROC, consiste en medir el **área bajo la curva**

o **AUC**, por sus siglas en inglés, que mientras más cercana esté a 1 significa que el modelo tiene un mejor desempeño (Géron, 2023):




Figura 2-2 Ejemplo de la curva ROC

Fuente: Géron, (2023)

2.3. Metodología CRISP-DM

El Cross Industry Standard Process for Data Mining o CRISP-DM, por sus siglas en inglés, es el marco de trabajo más utilizado para proyectos de análisis de datos y ciencia de datos, desde su introducción en 1999, aunque existen otras metodologías como la TDSP (Team Data Science Process Lifecycle) de Microsoft o la SEMMA del instituto SAS, entre muchas otras, la gran mayoría están basados en la metodología original de CRISP-DM, por lo que a día de hoy sigue siendo un estándar para la Industria del Machine learning. Consiste en dividir los proyectos en seis fases:

- **Entendimiento del negocio**, esta fase consiste en identificar el problema a resolver, que como buena práctica se enfoca en resolver el problema con mayor impacto para el negocio, y después especificar los requerimientos y recursos necesarios para el proyecto, luego el proyecto debe ser comunicado y finalmente definir cómo medir el éxito del proyecto.
- **Entendimiento de los datos**, tiene el propósito de definir las fuentes de datos necesarias para el proyecto, luego revisar la calidad y disponibilidad de los datos, se puede empezar con un análisis exploratorio de datos (Exploratory Data Analysis, EDA), mediante el cual se comprobará también si los datos son suficientes para resolver el problema definido antes.
- **Preparación de los datos**, es la fase más morosa de cualquier proyecto de analítica en general, consiste en revisar los datos, decidir cuáles serán los esenciales para el proyecto, luego serán transformados para facilitar su uso, es decir, se optimizará su calidad mediante técnicas como el borrado de datos corrompidos y nulos, o su reemplazo por alguna medida de tendencia central.

- **Modelado**, en esta fase, se genera la solución al problema inicial lo cual dependiendo del alcance determinado se logrará aplicando modelos y métodos de la analítica de datos, el desafío está en encontrar el modelo correcto.
- **Evaluación**, se trata de comparar el desempeño de las posibles soluciones encontradas, y discutir los resultados para poder encontrar el modelo que tenga una complejidad y desempeño más convenientes, en otras palabras, se debe decidir, que tiene más valor la interpretabilidad o el desempeño del modelo, a parte de los requisitos técnicos y procesos necesarios para el modelo.
- **Despliegue**, consiste en consolidar el conocimiento generado por el proyecto, incluye al modelo, las visualizaciones, código, etc. Luego evaluar cómo responden al problema inicial, y finalmente si es necesario implementar la solución encontrada en el sistema del negocio.

Cabe recalcar que las fases no son estrictamente lineales, se debe regresar y mejorar fases anteriores hasta encontrar la solución deseada (Jung, 2024).

2.4. Tendencias tecnológicas en la banca

La progresiva digitalización de los datos, derivados de la relación de negocios entre los bancos y sus clientes, ha hecho disponible varios tipos nuevos de información que ahora se pueden aprovechar en muchos aspectos por esta industria, mediante el desarrollo de modelos de Inteligencia Artificial, uno de los más relevantes es el modelado del riesgo crediticio. Mediante técnicas de Machine learning, se puede tomar ventaja de la capacidad computacional actual, para modelar este riesgo con menos restricciones, es decir, manejar un mayor número de variables, patrones y relaciones entre variables lo que permite la optimización y adaptabilidad del modelo basada en datos disponibles (Locatelli, Pepe, & Salis, 2022).

Aunque la digitalización se ha vuelto un estándar para los bancos, debido a todas las ventajas que ofrece, solo un 30% de los bancos han reportado una transformación digital exitosa, dónde algunos de los retos más comunes son: Subestimar la complejidad y los costos, cada iniciativa debe tener una duración y un presupuesto bien definidos, que contemplen el cambio de los procesos existentes, la participación de todos los equipos relevantes, desde analistas de riesgo hasta ejecutivos de negocio, etc. Y asegurar la implementación efectiva. También es relevante la medición correcta del impacto de una iniciativa, es necesario definir una manera clara para medir la relación entre los beneficios y la implementación de nuevas iniciativas tecnológicas, la falta de claridad en este sentido puede aumentar la resistencia al cambio, reduciendo la participación de los usuarios finales (Babbar, Janardhanan, Paternoster, & Soller, 2023).

2.5. Gestión del riesgo crediticio

Gestionar riesgos se trata de cuantificar la incertidumbre que rodea las actividades principales de una empresa, para lograr esto se debe identificar, medir y mitigar los riesgos, en este caso el riesgo crediticio. Dada la relación directa entre riesgo y recompensa, se pueden esperar ganancias solo bajo niveles adecuados de riesgo, lograr gestionar estos riesgos es una tarea esencial que permite generar reglas para hacer frente a los posibles eventos desfavorables (Corelli, 2024).

La gestión del riesgo crediticio se considera exitosa cuando es capaz de evitar las malas transacciones desde el principio, por lo que debe ser un proceso proactivo, buscando aceptar las transacciones que mejor se ajusten al área de experiencia de la organización, que se puedan monitorear y mitigar. Para lograr esto la entidad debe producir un conjunto de estrategias, políticas y procedimientos que permitan identificar de forma temprana los créditos con mayor riesgo, establecer criterios para la aprobación de los créditos, todo esto manejado por personal con un enfoque crítico hacia los modelos de estimación de riesgos, buscando que estos se refinan siempre con la evolución y nuevas tendencias del mercado (Koulafetis, 2017).

La responsabilidad de la gestión de riesgo crediticio se extiende al monitoreo de los reportes financieros de los clientes con créditos aprobados, dependiendo a la exposición al riesgo de cada crédito, de manera que se puedan tomar acciones correctivas oportunas en caso de que la capacidad de pago del cliente disminuya (Witzany, 2017). Dado que no es posible transformar un mal crédito en uno bueno solamente mediante la mitigación y monitoreo, la evaluación del riesgo crediticio es la principal actividad a diseñar y optimizar (Koulafetis, 2017).

2.5.1. Riesgo crediticio

Se trata de la probabilidad de que el prestatario incumpla parcial o completamente sus obligaciones financieras, causando pérdidas al prestamista. A pesar de ser ampliamente analizado es uno de los riesgos más complejos de medir, tradicionalmente se estudió mediante métodos actuarios de estimación, dado que es un factor esencial en la determinación de precios y rendimiento de las actividades financieras de los bancos. (Carlone, 2020).

Las fuentes donde se origina el riesgo crediticio son muy variadas, algunas de las más conocidas son los depósitos, los préstamos, los bonos, arrendamientos, acuerdos de recompra, entre otros (Koulafetis, 2017). El riesgo crediticio puede tomar muchas formas, debido a los diferentes tipos de contrapartes y obligaciones, pero usualmente aparece por la necesidad de un cliente, con intenciones de generar ganancias con el monto prestado, mientras que la entidad que otorga el crédito espera ser compensado por asumir este riesgo mediante el pago del interés acordado (Corelli, 2024). Para (Carlone, 2020), este riesgo se puede clasificar de las siguientes maneras:

- Riesgo de incumplimiento o default del crédito, es identificado por un banco cuando se cree probable que un cliente deudor se atrasará demasiado o no cumplirá en su totalidad con sus obligaciones crediticias.
- Riesgo de concentración, está asociado a las pérdidas que podrían generarse debido a que los clientes de un banco sean muy similares o pertenezcan a un sector económico en específico, que al verse afectados por condiciones externas no puedan cumplir con sus obligaciones crediticias.

2.6. Evaluación del riesgo crediticio

El objetivo principal de este proceso es aprobar solicitudes de crédito aceptables y rechazar a los clientes que puedan incumplir a futuro, también se encarga de fijar un precio que cubra las pérdidas crediticias mediante las tasas de interés que defina la entidad financiera. Evaluar correctamente el riesgo crediticio

depende de la capacidad que tenga el equipo encargado para reducir sesgos y tomar en cuenta los diferentes aspectos del negocio, por ejemplo, si esta tarea fuese encargada a un equipo de ventas, con comisiones por la cantidad y montos de créditos otorgados, probablemente no serían imparciales al revisar y aceptar las solicitudes de crédito, lo que causaría un aumento del incumplimiento de créditos, entonces a parte de la calidad del software o de los modelos que calculan este riesgo, se necesita reducir los riesgos operativos (Witzany, 2017).

2.6.1. Proceso tradicional de la evaluación de créditos

Los analistas de créditos consideran variables relevantes, cualitativas y cuantitativas, para poder aprobar o rechazar una solicitud de crédito, así como poder fijar una tasa de interés apropiada en cada caso. Su análisis puede automatizarse mediante modelos que estiman la probabilidad de default, aun así, la experiencia y las habilidades de los analistas los hacen indispensables para este sector, que suelen apoyarse en el resultado de estos modelos (Witzany, 2017).

De acuerdo con (Yhip & Alagheband, 2020), durante la evaluación de riesgo crediticio se deben evaluar dos factores, el primero es la capacidad del prestamista para pagar el crédito y el segundo es la garantía o el colateral que posee el cliente. Como punto de partida se usa el método de las “Cinco Cs”, se debe recolectar, analizar y evaluar información de las siguientes variables:

- Capacidad de pago, se intenta conocer la solvencia del cliente para pagar su préstamo incluyendo intereses en los plazos acordados, para estimarse confiablemente es necesario analizar los estados financieros.
- Capital, referido al patrimonio de los accionistas en la entidad financiera, es la cantidad de dinero que han invertido y que están arriesgando en caso de que el negocio falle, también se puede analizar a otros dos tipos de capitales, el primero es el capital regulatorio, para garantizar la estabilidad financiera de la entidad y cumplir con regulaciones y el segundo es el capital económico que se basa en la probabilidad de incumplimiento y la pérdida dado el incumplimiento.
- Colateral o garantía, es la fuente secundaria de la que se espera cobrar el crédito en caso de que ocurra el incumplimiento de la deuda, entonces se consideran los activos del cliente que pueden ser tangibles u otros como escrituras, incluso ingresos futuros (mercadería), para el prestamista es importante revisar y valorar estos activos acordes a la calidad en la que encuentren, es necesario también actualizar la valoración de estos activos en el tiempo. Lo que le importa a la entidad es conocer si el valor de venta de la garantía será suficiente para cubrir la pérdida esperada.
- Condición, se trata de las condiciones externas a la entidad que podrían afectar al crédito y que deben ser analizadas, algunas de estas son las tendencias del rubro del cliente, las condiciones del negocio del cliente, factores económicos como la inflación o las tasas de interés internacionales.
- Carácter o historial crediticio, conocer este factor de un cliente es importante para evitar el incumplimiento, dado que un mal historial puede indicar problemas con los pagos a futuro, en

otras palabras, se trata de estimar la responsabilidad y compromiso del cliente para pagar sus deudas.

2.6.2. Estimación del default de créditos

El default o incumplimiento se entiende como el retraso de los pagos del crédito acordado con el cliente, el tiempo de retraso que se considera como incumplimiento es definido por la entidad; el default puede causar una reestructuración de la deuda resultando en una obligación reducida a la que se acordó inicialmente, y aunque puede ocurrir por errores administrativos propios de la entidad, los que causan verdaderas pérdidas son los que están relacionados a la falta de capacidad o de voluntad de pago del cliente (Koulafetis, 2017). Modelar la probabilidad de default puede variar ampliamente por la manera en la que se decida estimar, se puede lograr esta tarea a partir de datos históricos o a través de la comparación con la probabilidad de default de bonos o también de swaps de incumplimiento (Carlone, 2020). Para estimar si un crédito caerá en default se puede utilizar alguno de los siguientes métodos:

- Modelos econométricos, que estiman la probabilidad de default mediante otras variables explicativas basadas en datos históricos, donde los que más destacan son el modelo de Merton, la regresión logística y más recientemente la aplicación de modelos de clasificación de machine learning.
- Modelos de “Shadow rating”, se basan en imitar las tasas decididas por agencias de calificación crediticia externas a la entidad, en especial para créditos de gran riesgo donde no se tienen suficientes datos.
- Sistemas basados en reglas, considera el proceso de toma de decisiones de los analistas más experimentados para estructurar reglas que imiten su forma de decidir, y así tener una base para la otorgación de créditos (Witzany, 2017).

3. Marco metodológico

3.1. Área de estudio

El área de estudio de este trabajo está situada en el departamento de Cochabamba, véase Figura 3-1, del Estado Plurinacional de Bolivia, dónde se encuentra la Cooperativa de Ahorro y Crédito Abierta “CACEF” R.L., situada sobre la Av. Ayacucho Nro. 331, en el municipio de Cercado, más precisamente en las siguientes coordenadas, latitud 17° 23' 23" S, longitud 66° 9' 34" W. Esta cooperativa fue fundada el 14 de diciembre de 1977 y recibió su personería jurídica el 28 de marzo de 1978 (Cooperativa CACEF R.L., 2025).



Figura 3-1 Área de Estudio, Cochabamba Bolivia

Fuente: SIARH, 2019

3.2. Flujograma metodológico

El desarrollo del proyecto se realizará en base a la metodología CRISP-DM, desglosado en la Figura 3-2:




Figura 3-2 Flujograma Metodológico

Fuente: Elaboración propia basado en CRISP-DM, 2025

3.3. Fuentes de información

3.3.1. Fuente de información secundaria

La fuente de datos principal es el conjunto de datos solicitado a la cooperativa “CACEF” y fue proporcionado de su sistema interno en formato Excel, contiene información de préstamos otorgados, montos, fechas de desembolso y vencimientos, tasas de interés, días de mora, variables demográficas de los clientes, etc. La cobertura de los datos va desde la gestión 2012 hasta el 31 de enero de 2025 y debido a la importancia y sensibilidad de la información financiera, algunos campos fueron enmascarados por razones de privacidad antes de ser compartidos para el desarrollo del presente proyecto, cómo se acordó pactado con la cooperativa, para ver una muestra de los datos ver Anexo 1.

3.4. Adquisición y análisis exploratorio de datos

3.4.1. Adquisición de los datos

Estos datos se obtuvieron mediante la coordinación con el equipo de TI de la cooperativa “CACEF”, mediante una solicitud realizada a la jefa de sistemas, mediante el documento “Requerimiento de Datos, Cacef.pdf”, que se encuentra en la carpeta “Documentos”, en el anexo principal (CD) del proyecto.

3.4.2. Estructura y características de los datos

El conjunto de datos contiene 5247 registros y 34 campos, para comprender mejor los datos se realizó la revisión de cada campo y se generó la Tabla 3-1.

Campo	Descripción	Tipo de dato
Id_credito	Identificador único de la cuenta o del crédito	Numérico (ID)
Id_socio	Identificador único del socio o cliente	Numérico (ID)
Fecha_desembolso	Fecha de desembolso del crédito	Categorico (Fecha)
Fecha_vencimiento	Fecha de vencimiento del crédito	Categorico (Fecha)
Tasa_interes	Tasa de interés nominal	Numérico
Moneda	Moneda del crédito (bolivianos o dólares)	Categorico
Forma_pago	Mecanismo de pago (cuota fija, amortizable, etc.)	Categorico
Periodo_amortizacion	Frecuencia con la que se cobra el crédito (mensual, trimestral, etc.)	Categorico

Cuotas_pactadas	Número total de cuotas acordadas	Numérico
Periodo_pago_interes	Frecuencia para el pago de intereses (en días o meses)	Numérico
Monto_desembolso	Monto desembolsado en la moneda original	Numérico
Saldo_credito	Saldo pendiente en la moneda original	Numérico
Tipo_cambio	Tipo de cambio aplicado si el crédito está en moneda extranjera	Numérico
Monto_diferido_bs	Monto diferido del crédito en bolivianos	Numérico
Monto_diferido_usd	Monto diferido del crédito en dólares	Numérico
Interes_diferido_bs	Interés diferido en bolivianos	Numérico
Interes_diferido_usd	Interés diferido en dólares	Numérico
Fecha_incumplimiento	Fecha de incumplimiento del pago de la última cuota	Categorico (Fecha)
Dias_mora	Número de días de atraso	Numérico
Estado	Estado del crédito (Vigente, Ejecución, etc.)	Categorico
Tipo_credito	Categoría del crédito (Microcrédito, Consumo, etc.)	Categorico
Destino_credito	Finalidad o uso del crédito (ej. capital de inversión, Consumo)	Categorico
Monto_garantia_bs	Valor de la garantía en bolivianos	Numérico
Monto_favor_bs	Monto a favor de la entidad (asegurado) en bolivianos	Numérico
Id_agencia	Sucursal o agencia que gestionó el crédito	Categorico
Fecha_nacimiento	Fecha de nacimiento del cliente	Categorico (Fecha)
Numero_creditos	Número total de créditos que se le otorgó al cliente (vigentes y cumplidos)	Numérico
Genero	Sexo del cliente (Masculino, Femenino)	Categorico
Estado_civil	Estado civil del cliente (Casado, Soltero, etc.)	Categorico
Ingresos_anual	Ingresos anuales declarados por el cliente	Numérico

Gastos_anual	Gastos anuales declarados por el cliente	Numérico
Departamento	Departamento o región donde reside el cliente	Categorico
Actividad_economica	Actividad económica (transportista, independiente, etc.)	Categorico
Antiguedad_actividad	Tiempo (en años) que lleva en la actividad	Numérico

Tabla 3-1 Estructura de los datos de “CACEF”.

Fuente: Elaboración propia, 2025

Algunas limitaciones que se identificaron en base al conjunto de datos compartidos son los siguientes:

- Cantidad de los datos, este factor afecta directamente al desempeño de los modelos, en especial a los modelos más complejos.
- Recursos computacionales, el tiempo para entrenar y validar a los modelos dependerá de las capacidades de cómputo disponibles para el proyecto académico presentado.
- Vigencia de los Resultados, el modelo se basa en datos históricos, asumiendo que factores como el comportamiento de los clientes y las condiciones del mercado se mantendrán estables, por lo que cualquier cambio en estos factores puede disminuir la precisión del modelo.

3.4.3. Exploración inicial

En esta etapa se realizó una revisión de las características del conjunto de datos utilizando el lenguaje de programación Python y en el entorno de los Notebooks de Google Colab como herramientas de análisis y visualización para descubrir patrones de los datos, por ejemplo, se hizo la revisión del tipo de datos, cantidad de valores nulos, cantidad de registros duplicados y medidas de tendencia central de cada campo, con el objetivo de determinar la calidad de los datos, también se creó la variable objetivo en base a la siguiente condición, si un crédito tiene 50 días de mora o más se considera default (1) y de otra manera es un crédito en cumplimiento (0).

3.4.4. Análisis univariado

En este análisis se desea descubrir principalmente las distribuciones de las variables numéricas, las frecuencias de las clases de las variables categóricas, la tendencia de los créditos otorgados por la cooperativa. Debido a la cantidad de variables a analizar se determinó la siguiente estrategia, se analizó separando las variables en 3 grupos, el primer grupo son las variables que describen a los clientes, el segundo las variables que describen a los créditos y finalmente las variables generales.

Se definió analizar las variables numéricas mediante gráficos de histograma y diagramas de caja con el fin de conocer su distribución, sesgos y valores atípicos, mientras que para las variables categóricas se realizaron gráficas de conteo de frecuencia en base al identificador de crédito, con el objetivo de conocer las categorías más comunes de cada campo. Para lograr estos análisis se crearon dos funciones en Python, que se encuentran detalladas en el Anexo 2 y el Anexo 3 respectivamente. Como muestra de lo que se obtiene con la primera función de las variables numéricas de clientes se obtuvo la Figura 3-3.




Figura 3-3 Histogramas y diagramas de caja de variables del cliente

Fuente: Elaboración propia, 2025

El número de créditos, los ingresos y gastos presentan una distribución asimétrica con una cola larga hacia la derecha, lo que indica que estas tres variables tienen valores atípicos muy altos a comparación,

de los demás valores, en general la gran mayoría de los datos se concentra en valores más bajos para estas tres variables, por ejemplo, la mediana para el número de créditos está en 3. Para la antigüedad de su actividad y la edad del cliente ambos presentan esta característica, pero en menor medida, se puede notar que la mayoría de los clientes están concentrados entre 4 y 22 años de antigüedad, y entre 34 y 56 años de edad.

De manera similar para las variables categóricas de los clientes, se obtuvieron gráficos de conteo que se pueden ver en la Figura 3-4 mostrada a continuación.




Figura 3-4 Gráfica de conteo para variables de cliente

Fuente: Elaboración propia, 2025

La mayoría de los créditos se otorgan a clientes varones, siendo alrededor de un 26% que se otorga a mujeres, otra característica que se puede ver es que el 61% créditos otorgados corresponden a personas casadas y casi un 30% a personas solteras, por lo que se podría unir las demás clases a alguna de estas dos, ya que son las más pobladas. De manera similar se puede ver que el 85% de los créditos se otorgan a personas independientes, en análisis de las variables restantes se puede desarrollará en el siguiente capítulo.

3.4.5. Análisis bivariado

Se utilizó la misma estrategia de separación en los grupos de variables ya mencionados, para esto se crearon funciones para graficar diagramas de caja separado por la variable objetivo (default) para las variables numéricas y para las variables categóricas se realizarán gráficos de barras apiladas al 100%, las cuales se detallan en los Anexos 4 y 5. Una vez más se detalló mejor los resultados en el capítulo siguiente pero como muestra de estas funciones, los resultados se pueden observar en la Figura 3-5.




Figura 3-5 Análisis bivariado de variables numéricas de cliente

Fuente: Elaboración propia, 2025

El número de créditos de los créditos de los clientes con default se concentra más abajo que los que cumplieron sus pagos, es decir, pueden ser clientes nuevos u clientes con un bajo perfil en la cooperativa, en el caso de los ingresos parece que no hay mucha diferencia al menos en la concentración incluso se nota que hay clientes que declararon ganar más pero aun así incumplieron, de forma similar los clientes

que incumplieron parecen declarar montos más bajos en cuanto a gastos anuales. Las siguientes dos variables parecen diferenciar mejor los casos de incumplimiento dado que la edad de los que incumple en cuanto a medianas parece ser ligeramente menor de igual manera para la antigüedad en su actividad económica.

Como se puede ver en la Figura 3-6, para las variables categóricas del cliente, se puede ver que porcentualmente más clientes mujeres incumplieron con sus obligaciones del total de créditos otorgados, según el estado civil, los clientes solteros incumplen más y finalmente todos los clientes clasificados como “empresario” incumplieron sus créditos, seguidos de los clientes que se dedican a ser comerciantes, prestar servicios u “otros”.




Figura 3-6 Análisis bivariado de variables categóricas de cliente

Fuente: Elaboración propia, 2025

3.4.6. Análisis de correlación

Para poder conocer la correlación entre variables numéricas se calcula el coeficiente de Pearson, el cual es una medida que se encuentra en el rango de -1 y 1, siendo el signo el que muestra si la relación es directa o inversa, es decir si las dos variables incrementan juntas o si una de ellas decrece mientras las otra incrementa, entonces mientras más cercano a la unidad se encuentre más fuerte será la correlación. Dado este conocimiento se calculó la correlación entre todas las variables numéricas y luego se creó una matriz de correlación, la cual ayuda a diferenciar visualmente la correlación entre todas las variables.

Se desea observar la correlación que se tiene entre los días de mora de los créditos y las demás variables, dado que los días de mora ayudaron a definir la variable objetivo, es importante ver que variables se correlacionan más con el objetivo. Para calcular el coeficiente de calor y generar el mapa de calor se utilizó el siguiente código.

```
columnas_numericas =
df_default.select_dtypes(include=['number']).drop('default',
axis=1).columns.sort_values()
# Definir el DF de variables numericas para el Calculo
df_num = df_default[columnas_numericas]

# Calcular la matriz de correlación Pearson
corr_matrix = df_num.corr()

# Graficar el heatmap
plt.figure(figsize=(12, 10))
sns.heatmap(corr_matrix, annot=True, fmt=".2f", cmap="RdBu", center=0)
plt.title("Matriz de Correlación entre Variables Numéricas")
plt.show()
```

3.4.7. Análisis de asociación

De manera similar a la correlación de Pearson, se tiene una medida de la fuerza de asociación entre variables categóricas, la cual se conoce como Cramér's V, la cual se basa en hallar el valor chi cuadrado, y junto a su tabla de consistencia poder hallar esta medida, en este caso va desde 0 al 1, mientras que el cálculo de la estadística chi cuadrado confirma si dos variables están asociadas o no, mediante el valor p obtenido, esta medida permite cuantificar la asociación que existe entre las variables. de dos variables categóricas. Entonces para visualizar de mejor manera la asociación entre variables se puede generar una matriz similar a la de correlación, con el propósito de analizar a las variables que se asocian más con el default. Para este propósito se usó el código mostrado a continuación:

```
def cramers_v(x, y):
    """
    Calcula Cramér's V para medir la asociación entre dos variables
    categóricas.
    """
```

```

confusion_matrix = pd.crosstab(x, y)
chi2 = stats.chi2_contingency(confusion_matrix)[0]
n = confusion_matrix.sum().sum()
r, k = confusion_matrix.shape
return np.sqrt(chi2 / (n * (min(r, k) - 1)))

```

Seguido de su implementación para graficar la matriz de asociación como mapa de calor.

```

matrix_size = len(cat_cols)
cramers_results = pd.DataFrame(np.zeros((matrix_size, matrix_size)),
                               index=cat_cols, columns=cat_cols)

for i in range(matrix_size):
    for j in range(i, matrix_size):
        v = cramers_v(df_default[cat_cols[i]], df_default[cat_cols[j]])
        crammers_results.iloc[i,j] = v
        crammers_results.iloc[j,i] = v # simétrico

# Heatmap de Cramér's V
plt.figure(figsize=(10,8))
sns.heatmap(cramers_results, annot=True, fmt=".2f", cmap="Reds",
            square=True)
plt.title("Matriz de Cramér's V entre Variables Categóricas")
plt.show()

```

3.5. Preparación de los datos

En base al análisis exploratorio realizado, se definieron estrategias para mejorar la calidad del conjunto de datos y así poder entrenar los modelos de una forma más eficiente. Para lograr esto se crearon pipelines de ScikitLearn y se incluyeron en ColumnTransformers para poder automatizar el proceso de preparación de datos.

3.5.1. Eliminación de variables

Dado que durante el análisis pueden verse variables con una cantidad muy alta de valores nulos, duplicados, y otros similares se considera la posibilidad de eliminar variables que no aporten valor al entrenamiento de los modelos, otro criterio importante que afecta a esta decisión es revisar que los datos no sean redundantes, es decir, que sean independientes entre ellos de manera que no se genere ruido.

En base a las observaciones del Análisis exploratorio realizado, se considera eliminar algunas variables debido a que no son independientes o son redundantes, por lo que no añaden valor al modelo, también se considera eliminar variables que el modelo no necesita como los identificadores únicos. Las variables que se eliminarán son las siguientes:

- Fecha de desembolso y fecha de vencimiento, debido a que ya se combinaron para generar la duración del crédito.

- Estado, debido a que está muy asociada a la variable objetivo, porque según la base de datos significan casi lo mismo, con la diferencia de que no se tiene un control manual confiable de esta variable, por eso es que algunos créditos aparecen como vencidos y en default o algunos ejecutados, pero con saldo en cero.
- Días de mora, debido a que ya se calculó la variable objetivo en base a esta variable, se descartará por que representan lo mismo.
- Identificadores, id del socio, id del crédito, id de la agencia son variables que solo identifican cada caso, pero no aportan al modelo.

```
df_default = df_default.drop(['fecha_vencimiento', 'fecha_desembolso',
                             'id_agencia', 'id_socio', 'id_credito', 'estado', 'dias_mora'], axis=1)
```

3.5.2. Tratamiento de valores nulos

Debido a que algunas variables son muy importantes y no se pueden eliminar, o tal vez no tienen una cantidad de nulos significativa se debe considerar la imputación de los valores faltantes, lo cual significa reemplazarlos por medidas de tendencia central, como ser la media, la mediana y para el caso de variables categóricas la moda.

En este caso, para el tratamiento de valores nulos, se observa que solo existen valores nulos en ingresos anuales y gastos anuales, y son alrededor de 46 casos, lo que representa un 0.93% de los registros en total, por lo que se utilizó la técnica de imputación con la mediana, es decir, se reemplazaran los datos nulos con la mediana de cada variable debido a que son datos altamente sesgados.

```
numericas = df_default.select_dtypes(include=['number']).drop('default',
                                                             axis=1).columns

df_default['ingresos_anual'] = df_default['ingresos_anual'].replace(0,
                                                                    np.nan)
df_default['gastos_anual'] = df_default['gastos_anual'].replace(0,
                                                                np.nan)

imputer = SimpleImputer(strategy='median')
df_default[numericas] = imputer.fit_transform(df_default[numericas])
```

3.5.3. Combinación de variables

Dada la alta correlación que se puede encontrar entre algunas variables es posible que el modelo logre aprender más de una combinación. Estas combinaciones pueden realizarse mediante sumas, restas, porcentajes, divisiones, o cualquier otro operador matemático, la idea es obtener una nueva variable que simplifique los datos, pero aporte lo mismo o más al modelo. En base al análisis de correlación se determinó combinar las variables de ingresos y gastos anuales, en una proporción, por ejemplo, gastos entre ingresos, de igual manera para las variables saldo y monto desembolsado se probará crear la variable porcentaje pagado que seria 1 menos el saldo entre el monto desembolsado.

```
# pct_pagado
df_default['pct_pagado'] = 1 - (df_default['saldo_credito'] /
df_default['monto_desembolso'])

# ratio_gastos_ingresos, manteniendo 0 si los ingresos son 0
df_default['ratio_gastos_ingresos'] = df_default['gastos_anual'] /
df_default['ingresos_anual']

# total_diferido
df_default['total_diferido'] = df_default['monto_diferido_bs'] +
df_default['interes_diferido_bs']
```

3.5.4. Agrupación de clases

La cantidad de clases que existen en cada variable categórica pueden ser muy grandes, y muchas de las clases observadas representan una cantidad muy baja de ejemplos lo que genera ruido, para reducir esto se agrupan las clases menos comunes en una sola o se unirán a alguna de las clases principales.

3.5.5. Tratamiento a valores atípicos

Los valores atípicos son valores que son demasiado altos o demasiado bajos a comparación de los valores que generalmente se encuentran en una variable, lo que produce una distribución sesgada y afectan negativamente a que el modelo encuentre patrones entre los datos, hay variables que tienen más sesgo que otras, uno de los primeros métodos que se podrían aplicar es el de eliminar los casos con valores atípicos, en base al rango intercuartil, pero se corre el riesgo de eliminar observaciones que pueden ser importantes para el entrenamiento, entonces primero se visualizó el sesgo de las variables para determinar cuales se transformarán y luego comparar su sesgo después de ser transformadas, por lo que en este caso se considera escalar las variables más sesgadas mediante el uso de transformaciones logarítmicas combinadas con el escalado robusto o como segunda opción se aplica el PowerTransformer de ScikitLearn.

```
pipeline_power = Pipeline([
    ('power', PowerTransformer(method='yeo-johnson'))
])

pipeline_num_log_std = Pipeline([
    ('log', log_transformer),
    ('scaler', StandardScaler())
])

pipeline_num_log_robust = Pipeline([
    ('log', log_transformer),
    ('scaler', RobustScaler())
])

ct_power_drop = ColumnTransformer([
    ('num_sesgada', pipeline_power, numericas_sesgada_sin_orig),
```

```

        ('num_no_sesgada', pipeline_num_no_log_std, numericas_no_sesgada),
        ('cat', pipeline_cat, categoricas)
    ])
ct_log_std_keep = ColumnTransformer([
    ('num_sesgada', pipeline_num_log_std, numericas_sesgada_total),
    ('num_no_sesgada', pipeline_num_no_log_std, numericas_no_sesgada),
    ('cat', pipeline_cat, categoricas)
])

```

3.5.6. One-Hot Encoding

Esta transformación se utiliza en las variables categóricas después de ser agrupadas, convirtiendo cada clase de una categoría específica en una columna donde cada columna tomará el valor de 0 cuando no corresponda a esa clase y el valor de 1 cuando si lo haga, de esta manera se convirtieron las clases en una variable binaria de modo que el modelo pueda aprender de las variables categóricas.

```

pipeline_cat = Pipeline([
    ('imputer', SimpleImputer(strategy='constant',
fill_value='faltante')),
    ('onehot', OneHotEncoder(handle_unknown='ignore'))
])

```

3.6. Entrenamiento de modelos

3.6.1. Separación de Conjunto de entrenamiento y evaluación

Para poder entrenar y evaluar cada modelo se debe separar los datos en un conjunto de entrenamiento, y otro conjunto de evaluación, que sirve para poder calcular las métricas de evaluación en la siguiente fase del proyecto. Se utilizó el siguiente código para obtener estos conjuntos de datos.

```

X = df_default.drop('default', axis=1)
y = df_default['default']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

```

Después definir los conjuntos necesarios, se procedió a obtener el pipeline base que permitirá integrar el preprocesamiento de datos, las técnicas de balanceo de datos y finalmente el entrenamiento de cada modelo.

```

pipeline_base = ImbPipeline([
    ('preprocessor', 'passthrough'), # se reemplazará en param_grid
    ('resampler', 'passthrough'), # se reemplazará en param_grid (SMOTE o
Undersampling)
    ('clf', None) # se definirá en param_grid
])

```


3.6.2. Técnicas de balanceo de clases

Dado que la variable objetivo es muy rara en el conjunto de datos, representando apenas un 1.8%, es necesario utilizar técnicas de balanceo, de manera que los modelos puedan tener mejor acceso a los datos que son de incumplimiento. Existen varias maneras de realizar esto, las que se utilizarán en este proyecto son las siguientes:

- **SMOTE (Synthetic Minority Over-sampling Technique)**, este método genera nuevos ejemplos sintéticos de la clase menos común, en lugar de duplicar las observaciones existentes, para esto identifica los puntos de la clase minoritaria y crea nuevos puntos al largo del espacio entre ellos. Sus estrategias son las siguientes:
 - **‘minority’**: Sobre muestrea solo la clase minoritaria,
 - **‘not majority’**: Sobre muestrea todas las clases menos la más común,
 - **‘all’**: Aplica sobre muestreo a la clase minoritaria y submuestreo a la clase mayoritaria para lograr un balance completo.
- **RandomUnderSampler**, selecciona aleatoriamente una cantidad reducida de muestras de la clase más común, equilibrando así su distribución, resulta útil para evitar el sobreajuste que puede ocurrir con SMOTE, si se generan muchas muestras sintéticas.

Las técnicas de balanceo de clases se definieron de la siguiente manera:

```
estrategias_smote = [
    SMOTE(random_state=42, sampling_strategy='minority'), # sobremuestrea
    solo la clase minoritaria
    SMOTE(random_state=42, sampling_strategy='all') # sobremuestrea ambas
    clases
]

estrategias_undersampling = [
    RandomUnderSampler(random_state=42, sampling_strategy='majority'), #
    Reduce solo la clase mayoritaria
]

resampling_strategies = estrategias_smote + estrategias_undersampling
```

3.6.3. Entrenamiento del modelo de Regresión Logística

Los hiperparámetros son valores configurables antes del proceso de entrenamiento que afectan el rendimiento del modelo, se pueden ajustar muchas variantes de los hiperparámetros a modo de hallar los que ofrecen mejor desempeño en cada modelo, para esto se utiliza GridSearchCV, Realiza una búsqueda exhaustiva de cada posible combinación en una malla predefinida de valores de hiperparámetros, y RandomizedSearchCV, que realiza lo mismo pero de manera aleatoria para optimizar el uso de recursos, por lo que no cubre todas las posibles combinaciones. A continuación, se describen algunos de los hiperparámetros ajustados para cada modelo y su significado. Los hiperparámetros por ajustar en este modelo se muestran en el código a continuación.

```

param_grid_lr = {
    'preprocessor': [
        ct_power_drop,
        ct_power_keep
    ],
    'resampler': resampling_strategies,
    'clf': [LogisticRegression(random_state=42)],
    'clf__C': [0.1, 1, 10, 50],
    'clf__class_weight': ['balanced'],
    'clf__penalty': ['l1', 'l2', 'elasticnet'],
    'clf__l1_ratio': np.linspace(0, 1, 5),
    'clf__max_iter': [100, 300, 500],
    'clf__solver': ['liblinear', 'saga']
}
grid_lr = GridSearchCV(
    pipeline_base,
    param_grid_lr,
    scoring=scoring,
    refit='average_precision',
    cv=5,
    n_jobs=-1
)
grid_lr.fit(X_train, y_train

```

También se ajustaron los hiper parámetros usando RandomSearchCV, según el código siguiente:

```

param_dist_lr = {
    'preprocessor': [
        ct_power_drop,
        ct_log_keep
    ],
    'resampler': resampling_strategies,
    'clf': [LogisticRegression(solver='saga', random_state=42)],
    'clf__C': uniform(0.1, 100),
    'clf__class_weight': ['balanced'],
    'clf__penalty': ['l1', 'l2', 'elasticnet'],
    'clf__l1_ratio': uniform(0, 1),
    'clf__max_iter': [100, 300, 500]
}
random_lr = RandomizedSearchCV(
    pipeline_base,
    param_distributions=param_dist_lr,
    scoring=scoring,
    refit='average_precision',

```

```

cv=StratifiedKFold(n_splits=5, shuffle=True, random_state=42),
n_jobs=-1,
n_iter=1000,
random_state=42
)
random_lr.fit(X_train, y_train)

```

3.6.4. Entrenamiento del modelo Random Forest

```

param_dist_brf = {
    'preprocessor': [
        ct_power_drop,
        ct_power_keep
    ],
    'resampler': [None],
    'clf': [BalancedRandomForestClassifier(random_state=42)],
    'clf__n_estimators': [100, 200, 500, 1000, 1500], # Número de árboles
    'clf__max_depth': [None, 10, 30, 50], # Profundidad de los árboles
    'clf__min_samples_split': [2, 4, 6], # Min. muestras para dividir
    'clf__min_samples_leaf': [1, 3, 5],
    'clf__max_features': ['sqrt', 'log2', 0.5, 0.75],
    'clf__class_weight': ['balanced', 'balanced_subsample'],
    'clf__bootstrap': [True, False]
}

random_brf = RandomizedSearchCV(
    pipeline_base,
    param_distributions=param_dist_brf,
    n_iter=1000,
    scoring=scoring,
    refit='average_precision',
    cv=5,
    n_jobs=-1,
    random_state=42,
    verbose=3
)
random_brf.fit(X_train, y_train)

```

3.6.5. Entrenamiento del modelo XGBoost

```

param_dist_xgb = {
    'preprocessor': [
        ct_power_drop,
        ct_power_keep
    ],

```

```

        'resampler': resampling_strategies,
        'clf': [xgb.XGBClassifier(random_state=42, use_label_encoder=False,
eval_metric='logloss')],
        'clf__n_estimators': randint(300, 400),
        'clf__learning_rate': uniform(0.01, 0.5),
        'clf__max_depth': randint(2, 7),
        'clf__min_child_weight': randint(1, 4),
        'clf__gamma': uniform(0, 0.4),
        'clf__subsample': uniform(0.8, 0.2),
        'clf__colsample_bytree': uniform(0.8, 0.2),
        'clf__reg_alpha': uniform(0, 10),
        'clf__reg_lambda': uniform(0, 10),
        'clf__scale_pos_weight': randint(50, 60)
    }
    random_xgb = RandomizedSearchCV(
        pipeline_base,
        param_distributions=param_dist_xgb,
        n_iter=2000,
        scoring=scoring,
        refit='average_precision',
        cv=5,
        n_jobs=-1,
        random_state=42
    )
    random_xgb.fit(X_train, y_train)

```

3.6.6. Entrenamiento del modelo Red Neuronal Profunda

```

ct_power_keep.fit(X_train)

X_train_transformed = ct_power_keep.transform(X_train)
X_test_transformed = ct_power_keep.transform(X_test)

def focal_loss(gamma=2., alpha=0.25):
    def loss(y_true, y_pred):
        y_pred = tf.keras.backend.clip(y_pred, 1e-7, 1 - 1e-7)
        pt = tf.where(tf.equal(y_true, 1), y_pred, 1 - y_pred)
        loss = -alpha * (1 - pt) ** gamma * tf.keras.backend.log(pt)
        return tf.keras.backend.mean(loss)
    return loss

classes = np.unique(y_train)
class_weights = compute_class_weight('balanced', classes=classes,
y=y_train)

```

```
class_weight_dict = {i: class_weights[i] for i in
range(len(class_weights))}

model = Sequential([
    Dense(128, input_dim=X_train_transformed.shape[1]),
    BatchNormalization(),
    LeakyReLU(),
    Dropout(0.1),

    Dense(64),
    BatchNormalization(),
    LeakyReLU(),
    Dropout(0.1),

    Dense(32),
    BatchNormalization(),
    LeakyReLU(),
    Dropout(0.1),

    Dense(1, activation='sigmoid')
])

model.compile(
    optimizer=Adam(learning_rate=0.0005),
    loss=focal_loss(),
    metrics=['Precision', 'Recall']
)

early_stopping = EarlyStopping(monitor='val_loss', patience=10,
restore_best_weights=True)

history = model.fit(
    X_train_transformed, y_train,
    epochs=100,
    batch_size=128,
    validation_data=(X_test_transformed, y_test),
    callbacks=[early_stopping],
    class_weight=class_weight_dict,
    verbose=1
)
```

3.7. Evaluación y selección de los modelos

3.7.1. Estrategia de validación

Para garantizar una evaluación y selección confiable del desempeño de los modelos, se emplearon dos enfoques principales:

Validación cruzada durante la búsqueda de hiperparámetros, Se utilizó GridSearchCV, que implementa validación cruzada k-fold con cv=5 de manera interna. Esto permitió evaluar múltiples combinaciones de hiperparámetros y seleccionar la mejor sin necesidad de un conjunto de validación separado, maximizando el uso de los datos de entrenamiento.

Evaluación con validación cruzada independiente, Para obtener una medida más robusta del rendimiento general del modelo, se utilizó validación cruzada estratificada (StratifiedKFold) con k=5. Este método mantiene la proporción original de las clases en cada pliegue, evitando que la clase minoritaria quede subrepresentada en algún subconjunto de validación.

3.7.2. Criterios de evaluación

Las métricas principales que evaluarán al modelo, serán las siguientes:

- Recall, permitirá conocer el porcentaje de créditos que el modelo detecta correctamente que están en default en los datos reales, es decir, identificar casos que son verdaderamente riesgosos.
- Precisión, estimará el porcentaje de predicciones de default acertadas del total predicho como default por el modelo, minimizando etiquetar como default a créditos de bajo riesgo.

Estas métricas se calcularon usando la validación cruzada, usando la siguiente función.

```
# Evaluación de modelos con validación cruzada
def evaluate_model(model, X_test, y_test):
    y_pred = cross_val_predict(model, X_test, y_test, cv=5,
method='predict')
    y_prob = cross_val_predict(model, X_test, y_test, cv=5,
method='predict_proba')[:, 1]
    # Matriz de confusión
    cm = confusion_matrix(y_test, y_pred)
    # Reporte de clasificación
    print("Reporte de Clasificación:\n", classification_report(y_test,
y_pred))
    # Curva ROC
    fpr, tpr, _ = roc_curve(y_test, y_prob)
    roc_auc = auc(fpr, tpr)
    # Curva PR
    precision, recall, _ = precision_recall_curve(y_test, y_prob)
    ap_score = average_precision_score(y_test, y_prob)

    return cm, roc_auc, fpr, tpr, precision, recall, ap_score
```

Una vez calculadas las métricas para cada modelo se procedió a generar las visualizaciones de las curvas ROC y PR se usó lo siguiente.

```
# Visualización de curvas ROC y PR
plt.figure(figsize=(12, 5))

# Subplot 1: ROC
plt.subplot(1, 2, 1)
for name, (cm, roc_auc, fpr, tpr, _, _, _) in evaluation_results.items():
    plt.plot(fpr, tpr, label=f'{name} (AUC={roc_auc:.2f})')
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('Curva ROC')
plt.legend()

# Subplot 2: PR
plt.subplot(1, 2, 2)
for name, (_, _, _, _, precision, recall, ap_score) in
evaluation_results.items():
    plt.plot(recall, precision, label=f'{name} (AP={ap_score:.2f})')
plt.xlabel('Recall')
plt.ylabel('Precision')
plt.title('Curva Precision-Recall')
plt.legend()

plt.show()
```

Mientras que para graficar las matrices de confusión de los se utilizó el siguiente código.

```
# Visualización de Matriz de Confusión
plt.figure(figsize=(10, 8))
for i, (name, (cm, _, _, _, _, _, _)) in
enumerate(evaluation_results.items()):
    plt.subplot(2, 2, i+1)
    sns.heatmap(cm, annot=True, fmt="d", cmap="Blues")
    plt.title(f'Matriz de Confusión - {name}')
    plt.xlabel('Predicho')
    plt.ylabel('Real')

plt.tight_layout()
plt.show()
```

3.7.3. Selección de los modelos

Una vez conocidos los resultados, se procede a realizar una tabla resumen, como la Tabla 3-2 que se ve a continuación, para poder seleccionar a aquellos modelos que presentaron un mejor rendimiento, de modo que se tenga documentado sus resultados más importantes, para futuras investigaciones.

Modelo	Recall	Precisión	PR-AUC	ROC-AUC	Seleccionado
Modelo 1	$R_1\%$	$P_1\%$	$PRA_1\%$	$ROC-A_1\%$	Si
Modelo 2	$R_2\%$	$P_2\%$	$PRA_2\%$	$ROC-A_2\%$	No
Modelo 3	$R_3\%$	$P_3\%$	$PRA_3\%$	$ROC-A_3\%$	No
Modelo 4	$R_4\%$	$P_4\%$	$PRA_4\%$	$ROC-A_4\%$	Si

Tabla 3-2 Ejemplo de Tabla de Resultados

Fuente: Elaboración propia

4. Análisis de los resultados y discusión

4.1. Análisis de los resultados del análisis exploratorio de datos

Durante el análisis inicial se determinó crear algunas variables de apoyo para el análisis posterior, estas son la duración estimada del crédito en meses, como la diferencia entre fecha de vencimiento y fecha de desembolso, y se creó la edad de los clientes basado en el campo de fecha de nacimiento y la fecha de corte (1 de enero de 2025), algunos de los hallazgos más importantes en esta etapa fueron los siguientes:

- No se encontraron créditos duplicados, por lo que se confirma que se cuenta con 5247 créditos únicos, que corresponden a 4565 socios de la cooperativa, lo que significa que en promedio existen 1.15 créditos por cada socio de la cooperativa.
- Las características más comunes de los créditos otorgados son que 99% están en moneda nacional, en promedio se otorgan Bs 88,296 con 14% de interés en promedio y una duración de 61 meses (aproximadamente 5 años), se amortizan con cuotas fijas de forma mensual.
- En cuanto a los clientes o socios, sus características son 75% son varones, de los cuales la mayoría están casados, en promedio los clientes tienen 44 años de edad, habitan en el departamento de Cochabamba, y son independientes en su actividad económica, perciben una mediana de Bs 66,000 como ingresos anuales, con una mediana en gastos anuales de Bs 26,500.
- Para la variable objetivo se analizó los días de mora de los créditos, se tiene que en promedio cada crédito tiene 17 días de mora, con una desviación estándar de 169 días, además se observa que el valor del tercer cuartil (75% de los datos) tiene un valor de 0, lo que indica que la gran mayoría de los créditos se cumplen con regularidad.
- Después de crear la variable objetivo se observa que aproximadamente un 1.8% de los créditos se incumplen, por lo que existe un desbalance a tomar en cuenta en la etapa de modelado.
- Los créditos que entran en default tienen un interés promedio de 16%, con un monto desembolsado promedio de Bs 88,238 y con un saldo de Bs 54,393 que se asume como pérdida para la empresa, el cual representa el 61.64% de pérdida por crédito que entra en default en promedio.

A partir de esto se decidió utilizar solo los créditos de moneda nacional, además de eliminar las variables de fecha de nacimiento y fecha de incumplimiento debido a la redundancia que generan.

Para el análisis univariado Se decidió analizar primero la variable de departamento primero, ya que fue la única variable general que se tiene, como se puede ver en la siguiente figura, los créditos otorgados en Cochabamba son el 95% del total de créditos, lo cual justifica al alcance del proyecto, y se tomó en cuenta solo estos créditos, como muestra la Figura 4-1.




Figura 4-1 Análisis univariado de departamento

Fuente: Elaboración propia, 2025

A continuación, se analizó las tendencias de la cantidad de créditos otorgados y el monto promedio desembolsado por semestre de la fecha de desembolso, Figura 4-2.




Figura 4-2 Cantidad de créditos otorgados y monto promedio desembolsado por semestre

Fuente: Elaboración propia, 2025

Se puede observar que la cantidad de créditos que la cooperativa ha otorgado ha ido incrementándose a través del tiempo, con una caída en los años de pandemia, pero llegó a un pico máximo en el año 2023, también es importante mencionar que el monto promedio desembolsado ha ido reduciéndose en el

tiempo, lo que podría señalar que la cooperativa ha optado por otorgar créditos menores con más frecuencia, posiblemente debido a que son de menor riesgo para la empresa.

Las tasas de interés más comunes van desde 11% hasta 14%, con ciertos casos atípicos que recibieron 7% de interés o menos o más de 17%. Para las cuotas pactadas se tiene una mediana de 24, lo que está relacionado con la duración del crédito que está concentrado entre 50 y 65 meses, finalmente para el periodo de pago de intereses se ve que es una variable discreta, concentra la mayor cantidad de observaciones entre 45 y 180 días, como muestra la Figura 4-3.




Figura 4-3 Histograma y diagrama de cajas para variables de crédito, parte 1

Fuente: Elaboración propia, 2025

Para el siguiente grupo de variables se generó la Figura 4-4 que se aprecia a continuación, la cual muestra los montos desembolsados, tiene que la mayoría de los créditos que se otorgaron están entre Bs 50,000 y Bs 100,000, también presenta valores atípicos que están sobre los Bs 210,000 otorgados, en cuanto al saldo de los créditos los valores parecen más estrechos hacia la izquierda lo que sugiere que la mayoría de los créditos están siendo pagados, mientras que también parece haber saldos muy elevados pero son considerados valores atípicos. Finalmente, para el monto e interés diferido o reprogramado, parece que la gran mayoría de créditos no los tiene, es decir, se pagan con puntualidad las cuotas, aunque existen varios valores atípicos que en este caso llegan hasta más de Bs 60,000.




Figura 4-4 Histograma y diagrama de cajas para variables de crédito, parte 2

Fuente: Elaboración propia, 2025

El último grupo de variables de crédito fueron los días de mora, que presentan una asimetría similar a la de los montos diferidos, es decir, se concentran en 0 lo que corrobora que los créditos se pagan puntualmente, los valores atípicos llegan hasta más de 4000 días de mora. En cuanto a la garantía y su monto a favor requeridos para la otorgación de créditos también se centran en 0, por lo que la gran mayoría de créditos no tienen garantía, se asume que son créditos pequeños de bajo riesgo, mientras que para aquellos créditos que si los tienen suelen tener valores muy altos que llegan hasta los 40 millones de bolivianos. Como se ve en la Figura 4-5, a continuación.




Figura 4-5 Histograma y diagrama de cajas para variables de crédito, parte 1

Fuente: Elaboración propia, 2025

Para las variables categóricas se elaboraron los gráficos que se muestran en la Figura 4-6, se observa que el 50% de los créditos se pagan mensualmente con cuotas fijas (86%) o cuotas amortizables (13%), la gran mayoría de los créditos están vigentes (97%) y muy pocos fueron vencidos hasta el momento (0.7%), se puede corroborar que la gran mayoría de los créditos son microcréditos para el sector agropecuario (51%) o son créditos de consumo (24%), destinados como capital de inversión (60%) o a la libre disposición del cliente (34%).




Figura 4-6 Gráficos de barra de variables de crédito

Fuente: Elaboración propia, 2025

Se puede mencionar que tanto el tipo de periodo de amortización podría descartarse al tener las cuotas pactadas, también se puede pensar agrupar a los tipos de créditos para reducir la cantidad de categorías, o bien quedarse con el destino del crédito, ya que podrían aportar la misma información al modelo, lo cual se comprobará con un análisis de asociación de variables categóricas.

La Figura 4-7 muestra los diagramas de caja para las variables de crédito, en primer lugar, se puede notar que los créditos que se incumplieron tienen tasas de interés más altas, y mucho más variables, como media tienen 14.2%, a comparación del 11% como mediana de los créditos que no incumplieron. Mientras que, para las cuotas, se concentra entre 30 y 55 cuotas para los créditos en default, lo cual es distinto para la duración del crédito dado que los créditos que se incumplen tienen a durar más de 55 meses como mediana, el pago de intereses parece ser más bajo concentrado en 30 para los créditos que se están en default. Y no parece haber diferencias entre estos grupos en cuanto al monto otorgado y al saldo de estos créditos.




Figura 4-7 Análisis bivariado de variables de crédito, parte 2

Fuente: Elaboración propia, 2025

El monto diferido para los créditos con default se ven más elevados, con un IQR de entre Bs 0 a Bs 6000, esto no es el caso con el interés diferido que se mantiene muy cercano a 0, lo que podría indicar que los clientes con default reprograman el pago a capital, el monto de garantía de la mayoría de créditos en default está en 0 o alrededor de este, mientras que el monto a favor es ligeramente concentrado desde Bs 0 hasta Bs 20,000, finalmente los días de mora son más altos concentrados entre 450 y 1200 días para los créditos en default, como se muestra en la Figura 4-8.




Figura 4-8 Análisis bivariado de variables de crédito, parte 3

Fuente: Elaboración propia, 2025

Analizando las variables categóricas de los créditos se observa la Figura 4-9, se ve que el incumplimiento sucede más en créditos con periodos mensuales o semestrales en un 5%, también se puede ver que esto sucede más seguido para créditos amortizables en 2%, de los créditos vencidos arriba del 80% tienen default, y parece que ocurren más a menudo en créditos de vivienda sin garantía hipotecaria en un 8%, y microcréditos con garantía real 5%, también se puede notar que los créditos que se destinan como capital de operaciones con 7% o ampliación y refacciones con 5% de default en las observaciones.




Figura 4-9 Análisis bivariado de variables categóricas de crédito

Fuente: Elaboración propia, 2025

La Figura 4-10 muestra el análisis de correlación entre variables numéricas se encontró que las variables más correlacionadas con los días de mora son las cuotas la antigüedad (-0.07), los ingresos anuales (0.06), la tasa de interés (0.05), las cuotas pactadas (0.05), el periodo de pago de interés (-0.05), entre otros.

Entre las mismas variables las correlaciones más notables son, antigüedad y tasa de interés (-0.29), cuotas pactadas y antigüedad (-0.3), monto diferido y monto a favor (0.39). Parecen indicar que a mayor antigüedad en su actividad se ofrecen menores tasas de interés y menos cuotas pactadas tienen, también que los montos diferidos aumentan según el monto a favor.




Figura 4-10 Matriz de correlación

Fuente: Elaboración propia, 2025

En la Figura 4-11 se ve el análisis de asociación entre las variables categóricas se observa que una de las más importantes es que el default se asocia fuertemente con el estado del crédito (98%) por lo que es posible que sea la misma información para el modelo, el segundo factor importante para el default es la actividad económica (32%) y en menor medida se ve que el estado civil del cliente también está asociado al default (11%), finalmente el tipo de crédito (10%) y el periodo de amortización (10%) igual están asociados a esta variable.

Entre las variables categóricas se puede notar que el periodo de amortización está fuertemente asociado a la forma de pago (73%), lo mismo ocurre con el destino del crédito y el tipo de crédito (67%) que podrían estar ofreciendo la misma información al modelo




Figura 4-11 Matriz de asociación

Fuente: Elaboración propia, 2025

4.2. Análisis de los resultados de la preparación de datos

Para reducir el sesgo de las variables observadas se realizó las transformaciones mencionadas en el capítulo anterior y la comparación de los sesgos obtenidos, ayudó a determinar que se usará el método de PowerTransformer, ya que es el que mejor reduce los sesgos o skewness en general como se muestra en la Figura 4-12, a continuación.




Figura 4-12 Sesgos antes y después de las transformaciones

Fuente: Elaboración Propia, 2025

4.3. Análisis de los resultados del entrenamiento de los modelos

4.3.1. Hiperparámetros optimizados para la regresión logística

Para la Regresión Logística, se empleó RandomizedSearchCV con validación cruzada para encontrar los hiperparámetros más óptimos. Se seleccionó la penalización elasticnet, la cual permite combinar L1 y L2, logrando un balance entre reducción de dimensionalidad y regularización. El hiperparámetro C, que controla la fuerza de la regularización, se estableció en 4.0766, permitiendo mayor flexibilidad en los coeficientes.

Además, se ajustó L1_ratio a 0.6041, definiendo el peso relativo entre L1 y L2. Para mejorar la convergencia, el número máximo de iteraciones se fijó en 500. Se utilizó el solver saga, compatible con grandes conjuntos de datos y con la regularización seleccionada. Dado el alto desbalance del dataset, se aplicó class_weight='balanced', lo que permitió ajustar automáticamente los pesos de cada clase.

4.3.2. Hiperparámetros optimizados para XGBoost

El modelo XGBoost se optimizó utilizando RandomizedSearchCV, buscando maximizar el desempeño en la clasificación del default. Se estableció un número de 285 estimadores, con una tasa de aprendizaje (learning_rate) de 0.0854, que equilibra velocidad y precisión en la convergencia.

La profundidad máxima de los árboles (`max_depth`) se fijó en 7, mientras que el peso mínimo para dividir un nodo (`min_child_weight`) se ajustó a 5, previniendo sobreajuste. La fracción de columnas utilizadas en cada árbol (`colsample_bytree`) se estableció en 0.9083, mientras que el muestreo de filas (`subsample`) se configuró en 0.8605, promoviendo la diversidad en los árboles.

Para regularización, se aplicó `reg_alpha=2.4691` y `reg_lambda=8.3855`, reduciendo la varianza del modelo. Adicionalmente, se empleó un `gamma` de 0.0771, que impide la creación de nodos de baja ganancia informativa. Finalmente, el hiperparámetro `scale_pos_weight=47` se ajustó para compensar el desbalance de clases, dándole mayor peso a la clase minoritaria.

4.3.3. Hiperparámetros optimizados del árbol aleatorio

En el modelo de Bosque Aleatorio, se realizó una búsqueda de hiperparámetros para encontrar el balance entre generalización y capacidad predictiva. Se configuró el número de árboles (`n_estimators`) en 100, con una selección de atributos por nodo limitada al 75% del total (`max_features=0.75`), promoviendo la diversidad de los árboles individuales. Para la profundidad máxima de los árboles (`max_depth`), se estableció en 10, evitando árboles excesivamente complejos. La división mínima para generar nodos internos (`min_samples_split`) se fijó en 6, mientras que el número mínimo de muestras por hoja (`min_samples_leaf`) se mantuvo en 1, permitiendo la captura de patrones más finos.

Se utilizó `bootstrap=True`, asegurando que cada árbol se entrenara con una muestra aleatoria del conjunto de datos. Finalmente, dado el desbalance del dataset, se aplicó `class_weight='balanced_subsample'`, permitiendo que cada árbol tenga un ajuste de peso proporcional a la distribución de clases dentro de su subconjunto de datos.

4.3.4. Hiperparámetros optimizados de la red neuronal profunda

Para el desarrollo del modelo de red neuronal profunda (DNN), se realizó una optimización de hiperparámetros con el objetivo de mejorar la capacidad del modelo para clasificar correctamente los casos de default. La arquitectura final consistió en una red con tres capas ocultas, cada una con un número decreciente de neuronas (128, 64 y 32), aplicando normalización por lotes (Batch Normalization) y activación LeakyReLU en cada capa. Además, se incorporaron capas de Dropout con una tasa de 10% para reducir el sobreajuste.

En cuanto a la configuración del entrenamiento, se utilizó el optimizador Adam con una tasa de aprendizaje de 0.0005, lo que permitió una convergencia estable. Para abordar el desbalance de clases, se calcularon los pesos de clase con `compute_class_weight`, favoreciendo la clase minoritaria (default). Asimismo, se implementó Focal Loss con parámetros $\alpha=0.25$ y $\gamma=2$ para enfocar el aprendizaje en los casos más difíciles de clasificar. El modelo se entrenó durante un máximo de 100 épocas con un tamaño de lote de 128, utilizando validación cruzada con un conjunto de prueba. Para evitar el sobreajuste, se implementó Early Stopping con un criterio basado en la pérdida de validación y una paciencia de 10 épocas.

4.4. Análisis de los resultados de la evaluación de los modelos

La evaluación de los modelos se realizó por pares, la Figura 4-13 muestra el resultado de comparar los dos modelos de Regresión Logística, uno fue entrenado con usando GridSearchCV y el otro con RandomSearchCV, ambos obtuvieron un Recall de 38.9% y una precisión del 4.9% y 5.1% respectivamente, también se ve que el ROC-AUC de ambos modelos es de 73%, mientras que el PR-AUC muestra un valor de 5%.




Figura 4-13 Evaluación del modelo de Regresión Logística

Fuente: Elaboración Propia, 2025

En la Figura 4-14 se muestran los siguientes modelos evaluados, que son el Random Forest, con un Recall de 33.3% y una precisión de 2.4%, además tiene un ROC-AUC de 64.1%, y una PR-AUC de 5%. A lado se tiene al modelo XGBoost con un Recall de 5.56% y una precisión de 2.7% con un ROC-AUC de 61% y una PR-AUC de 4%.




Figura 4-14 Evaluación de modelos Bosque Aleatorio y XGBoost

Fuente: Elaboración propia, 2025

Para la evaluación de la Red Neuronal Profunda, se obtuvo la gráfica 4-15, los resultados son 55.6% de Recall, 40% de precisión y una curva PR-AUC de 37% y un ROC-AUC de 89%, los cuales muestran una mejora importante a comparación de los anteriores modelos.




Figura 4-15 Evaluación de la Red Neuronal Profunda

Fuente: Elaboración propia, 2025

4.4.1. Selección de los modelos

Cómo se puede ver en la Tabla 4-1, los modelos seleccionados por su desempeño en cuanto a recall y precisión son la Red Neuronal Profunda, la Regresión Logística Random y finalmente el Random Forest.

Modelo	Recall	Precisión	PR-AUC	ROC-AUC	Seleccionado
Regresión Logística Random	38.9%	5.1%	5%	73%	Si
Regresión Logística Grid	38.9%	4.9%	5%	73%	No
Random Forest	33%	2.4%	5%	64.1%	No
XGBoost	5.6%	2.7%	4%	61%	No
Red Neuronal	55.6%	40%	37%	89%	Si

Tabla 4-1 Resumen de resultados de la evaluación y selección de modelos

Fuente: Elaboración propia, 2025

4.5. Discusión de los resultados

Se puede ver en la Figura 4-16, el estudio realizado por (González Schleissner, 2023), obtuvo un Recall de 99.3% y una Precisión de 99.9% utilizando un modelo de Red Neuronal simple, con 3 capas ocultas todas con una función de activación ReLu y una capa sigmoide para obtener la clasificación binaria, cabe recalcar que se usó una base de datos de 300,000 registros, con al menos el 20% representando a la clase minoritaria a clasificar.




Figura 4-16 Matriz de confusión del modelo de Red Neuronal

Fuente: (González Schleissner, 2023)

De igual manera el mismo autor utilizó el modelo XGBoost y obtuvo un Recall de 99.82% y una precisión del 100%, como se muestra en la Figura 4-17, lo cual contrasta bastante con el modelo XGBoost entrenado en el presente proyecto, el cual fue el modelo con más bajo desempeño, ver Tabla 4-1





Figura 4-17 Matriz de confusión del modelo de XGBoost

Fuente: (González Schleissner, 2023)

Por otro lado, (Ossa Giraldo & Jaramillo Marín, 2021), en su estudio evaluaron el ROC, ver Figura 4-18, de sus modelos entrenados para clasificar el default de una empresa Fintech de Colombia, usando una base de datos de 15,096 registros y 18 variables. Obtuvieron para sus modelos de Regresión logística y Linear SVM un ROC-AUC de 76%, en contraste al 73% que obtuvo el modelo de Regresión Logística



Random de la presente monografía, también se ve que para el Random Forest y Perceptron (Red Neuronal) se tiene un 74% como ROC-AUC, el cual es mayor al 64% del modelo Random Forest entrenado en esta monografía.

Figura 4-18 Curvas ROC de los modelos entrenados

Fuente: (Ossa Giraldo & Jaramillo Marín, 2021)

Como modo de comparación se observa la Tabla 4-2, que muestra que los modelos más óptimos que obtuvieron son Regresión Logística y Linear SVM con 83% de Recall a comparación del 39% obtenido por el modelo de Regresión Logística de esta monografía, es importante notar que ningún modelo entrenado en su proyecto supero los 30% de precisión, lo cual tiene sentido considerando que sus datos presentan un 14% de desbalanceo en sus datos de entrenamiento (Ossa Giraldo & Jaramillo Marín, 2021).

Modelo	Accuracy	Precisión	Recall	F1	AUC
Regresión logística	59%	23%	<u>83%</u>	36%	<u>76%</u>
Random Forest	<u>77%</u>	<u>30%</u>	51%	<u>38%</u>	74%
Linear SVM	58%	22%	<u>83%</u>	35%	<u>76%</u>
ML Perceptron	63%	23%	73%	35%	74%

Tabla 4-2 Métricas de Evaluación de los modelos

Fuente: (Ossa Giraldo & Jaramillo Marín, 2021)

5. Conclusiones

Durante el análisis de variables se encontró que ciertos factores tienen una mayor relación con el default de pagos. Algunos de ellos son la tasa de interés, la cual se identificó como una de las variables más importantes, observándose que los créditos en default tienden a tener tasas de interés más altas (15% como mediana) y con mayor variabilidad. Asimismo, se encontró que los créditos con plazos de duración superiores a 55 meses tienen una mayor probabilidad de entrar en default. También se evidenció que los clientes que caen en default suelen reprogramar el pago del capital en lugar de los intereses. En cuanto a los créditos en default se puede ver que el 92% ocurren en el departamento de Cochabamba, siendo un 32% otorgados como créditos de consumo libre, en su mayoría (63%) a varones con una edad promedio de 38 años, estos créditos en default representan una pérdida promedio de Bs 54,394 para la cooperativa.

En cuanto a la preparación del conjunto de datos se identificaron y eliminaron variables redundantes como ser fechas, identificadores, también se utilizó filtros para obtener la información relevante para el departamento de Cochabamba el cual representa el 95% de los créditos, luego se realizó ingeniería de características (Feature Engineering) para lograr obtener mejorar la calidad de los datos, lo cual implicó realizar imputación de variables numéricas por la mediana, la agrupación de clases para las variables categóricas reduciendo hasta un 20% las clases disponibles, también se redujo hasta un 90% el sesgo encontrados en la mayoría de las variables categóricas.

La limitación principal del proyecto, entrenamiento de los modelos fue el alto desbalance de clases, ya que solo el 2% de los créditos estaban en default. Aunque se aplicaron técnicas de remuestreo como SMOTE para reducir este problema, la precisión del modelo se vio afectada, reflejando un alto número de falsos positivos. Además, la disponibilidad y calidad de los datos pueden haber influido en los resultados, ya que algunas variables categóricas contienen clases que representan un 5% o menos de los datos.

Al realizar la evaluación sobresalieron la red neuronal profunda (DNN) y la regresión logística (LR) como los modelos que obtuvieron un mejor desempeño. Las redes neuronales lograron un recall del 55.6% y una precisión del 40%, superando a la regresión logística, que obtuvo un recall del 39% y una precisión del 5%, el modelo Random Forest obtuvo 33% de Recall y 2.4% de Precisión, finalmente se tiene al modelo XGBoost con 5.6% de Recall y 2.6% de Precisión. Esto significa que, aunque la DNN tiene una precisión moderada, es capaz de identificar una mayor cantidad de créditos en riesgo de default en comparación con los demás modelos. La regresión logística, por su parte, presentó un recall menor y una precisión muy baja, lo que sugiere que tiene dificultades para diferenciar correctamente entre créditos cumplidos e incumplidos, pero es una opción viable que consume menos recursos y es más fácil de interpretar.

6. Recomendaciones

Para mejorar el desempeño del modelo y su aplicabilidad en la clasificación de créditos de la cooperativa, es necesario mejorar el proceso de recolección de datos. Actualmente, muchas variables presentan sesgos significativos debido a la gran cantidad de valores en cero, lo que limita la capacidad del modelo para identificar patrones más precisos. Particularmente, variables clave como ingresos, gastos y otras métricas financieras de los clientes requieren un registro más detallado y completo. Además, mejorar la captura de información sobre la actividad económica permitiría disponer de datos más representativos y relevantes para la evaluación del riesgo crediticio.

También se recomienda fortalecer el modelo mediante la integración de datos externos, de ser posible, historiales crediticios de otras instituciones financieras o indicadores económicos del mercado. La implementación de un monitoreo continuo del modelo también resultaría beneficiosa, permitiendo ajustar los parámetros y la estrategia en función de nuevos datos y tendencias del mercado. Por otro lado, la exploración de arquitecturas más avanzadas en redes neuronales, con ajustes en hiperparámetros y estrategias de regularización, podría mejorar su capacidad de generalización y precisión.

Finalmente, considerando que las tasas de interés más altas y los plazos de crédito más largos están asociados con un mayor riesgo de incumplimiento, la cooperativa podría revisar su estrategia de asignación de tasas y plazos. Esto permitiría reducir la exposición al riesgo sin comprometer el acceso al crédito para clientes confiables. En conjunto, estas mejoras contribuirían a una clasificación más eficiente de los créditos y a una mejor toma de decisiones en la cooperativa.

Referencias bibliográficas

- Babbar, A., Janardhanan, R., Paternoster, R., & Soller, H. (11 de Abril de 2023). *Why most digital banking transformations fail, and how to flip the odds*. Obtenido de McKinsey Digital: <https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/tech-forward/why-most-digital-banking-transformations-fail-and-how-to-flip-the-odds>
- BBVA. (15 de Julio de 2024). *'Machine learning': ¿qué es y cómo funciona el maestro en reconocer patrones?* Obtenido de BBVA: <https://www.bbva.com/es/innovacion/machine-learning-que-es-y-como-funciona/>
- Carlone, G. (2020). *Introduction to Credit Risk*. Londres: CRS Press.
- Cooperativa CACEF R.L. (2025). *Nosotros*. Obtenido de CACEF: <https://cacef.coop/web/nosotros/>
- Corelli, A. (2024). *Understanding Financial Risk Management*. Londres: Emerald.
- Géron, A. (2023). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. Sebastopol: O'Reilly Media.
- González Schleissner, P. (2023). ESTUDIO DEL RIESGO DE CRÉDITO Y SU MARCO NORMATIVO PARA LA PREDICCIÓN DE LA PROBABILIDAD DE DEFAULT EMPLEANDO TÉCNICAS DE MACHINE LEARNING. (*Estudio de Pregrado*). Comillas Universidad Pontificia, Madrid.
- Hermitaño Castro, J. A. (29 de Julio de 2022). *Aplicación de Machine Learning en la Gestión de Riesgo de Crédito Financiero: Una revisión sistemática*. Obtenido de Interfases: <https://doi.org/10.26439/interfases2022.n015.5898>
- Hurbans, R. (2020). *Artificial Intelligence Algorithms*. Nueva York: Manning Publications Co.
- Jung, D. (2024). *The Modern Business Data Analyst: A Case Study Introduction into Business Data Analytics with CRISP-DM and R*. Cham: Springer.
- Kaabar, S. (2024). *Deep Learning for Finance: Creating Machine & Deep Learning Models for Trading in Python*. Sebastopol: O'Reilly Media.
- Kenneth, M. S. (1984). Loans of ancient Rome. *Accounting Historians Notebook*, 22-23.
- Koulafetis, P. (2017). *Modern Credit Risk Management, Theory and Practice*. Londres: Palgrave Macmillan.
- Lau, S., Gonzalez, J., & Nolan, D. (2023). *Learning Data Science: Data Wrangling, Exploration, Visualization and Modeling with Python*. Sebastopol: O'Reilly Media.
- Leleko, S., & Chupryna, R. (5 de Abril de 2024). *Using Machine Learning in the Banking Sector*. Obtenido de SPD Technology: <https://spd.tech/machine-learning/machine-learning-in-banking/>

- Li, H. (2019). *Machine Learning Methods*. Singapur: Tsinghua University Press & Springer Nature.
- Locatelli, R., Pepe, G., & Salis, F. (2022). *Artificial Intelligence and Credit Risk, The Use of Alternative Data and Methods in Internal Credit Rating*. Cham: Palgrave Macmillan.
- McMahon, A. P. (2023). *Machine Learning Engineering with Python*. Birmingham: Packt Publishing Ltd.
- O'Brien, K., & Downie, A. (1 de Mayo de 2024). *What is AI in banking?* Obtenido de IBM: <https://www.ibm.com/think/topics/ai-in-banking>
- Ossa Giraldo, W., & Jaramillo Marín, V. (2021). Machine Learning para la Estimación del Riesgo de Crédito en una Cartera de Consumo. (*Monografía de Maestría*). Universidad EAFIT, Medellín.
- Ozdemir, S. (2024). *Principles of Data Science*. Birmingham: Packt Publishing Ltd.
- Paul, T. (31 de Octubre de 2024). *When did credit scores start? A brief look at the long history behind credit reporting*. Obtenido de CNBC: <https://www.cnbc.com/select/when-did-credit-scores-start/>
- SIARH. (3 de Noviembre de 2019). *SEDERI Cochabamba*. Obtenido de Siarh.gob.bo: <https://siarh.gob.bo/2019/11/sederi-cochabamba/>
- Singh, J. (6 de Enero de 2024). *History and Evolution of Financial Lending: Trend Analysis*. Obtenido de Medium: <https://medium.com/design-bootcamp/history-and-evolution-of-financial-lending-trend-analysis-279f80971464>
- Solano Padilla, K. O., & Quimi Andrade, C. B. (20 de Enero de 2024). *Estado del arte de Modelos de LA en asignación de créditos bancarios*. Obtenido de UPS: <https://dspace.ups.edu.ec/bitstream/123456789/27861/1/UPS-GT005352.pdf>
- Witzany, J. (2017). *Credit Risk Management: Pricing, Measurement, and Modeling*. Cham: Springer International Publishing AG.
- Yhip, T. M., & Alagheband, B. M. (2020). *The Practice of Lending, A Guide to Credit Analysis and Credit Risk*. Cham: Palgrave Macmillan.

Anexos

Anexo 1 Vista previa del conjunto de datos

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
1	id_credito	id_socio	fecha_desembolso	fecha_vencimiento	tasa_interes	moneda	forma_pago	periodo_amortizacion	cuotas_pactadas	periodo_pago_interes	monto_desembolso	saldo_credito	tipo_cambio	monto_diferido_bs	monto_diferido_usd	interes_diferido_bs
2	360222	49120	7/1/2017	6/11/2018	15.6	BOLIVIANOS	AMORTIZABLI	MENSUAL	11	30	7,333.33	5,333.32	6.86	0.00	0.00	0.00
3	360304	49256	10/19/2017	3/20/2026	13	BOLIVIANOS	CUOTA FIJA	MENSUAL	60	30	160,000.00	29,929.08	6.86	24,356.12	0.00	9,687.44
4	360321	49124	11/17/2017	3/20/2034	12.95	BOLIVIANOS	CUOTA FIJA	MENSUAL	114	30	165,000.00	53,053.06	6.86	27,636.92	0.00	9,756.12
5	360323	48670	11/24/2017	7/15/2028	15	BOLIVIANOS	CUOTA FIJA	MENSUAL	43	30	70,000.00	12,320.41	6.86	10,529.08	0.00	4,644.95
6	360338	50726	12/26/2017	11/16/2026	15	BOLIVIANOS	CUOTA FIJA	MENSUAL	60	30	56,000.00	11,624.88	6.86	8,348.21	0.00	3,674.40
7	360389	51373	3/28/2018	6/5/2025	22	BOLIVIANOS	CUOTA FIJA	MENSUAL	60	30	35,000.00	3,679.59	6.86	4,771.06	0.00	4,006.57
8	360396	48888	4/23/2018	4/20/2024	22	BOLIVIANOS	CUOTA FIJA	MENSUAL	36	30	15,000.00	0.00	6.86	1,007.37	0.00	51.52
9	360400	51558	4/28/2018	9/4/2028	15	BOLIVIANOS	CUOTA FIJA	MENSUAL	60	30	95,000.00	41,108.37	6.86	14,709.65	0.00	7,282.25
10	360410	49127	5/28/2018	1/5/2031	12.95	BOLIVIANOS	CUOTA FIJA	MENSUAL	84	30	250,000.00	147,300.98	6.86	21,611.78	0.00	19,538.98
11	360422	52005	6/28/2018	2/5/2029	16	BOLIVIANOS	CUOTA FIJA	MENSUAL	60	30	115,453.58	59,602.93	6.86	10,386.69	0.00	7,610.71
12	360423	48504	6/29/2018	7/10/2027	12.95	BOLIVIANOS	CUOTA FIJA	MENSUAL	110	30	170,000.00	55,627.70	6.86	23,619.52	0.00	11,894.96
13	360457	48670	9/24/2018	1/5/2024	14	BOLIVIANOS	CUOTA FIJA	MENSUAL	36	30	17,000.00	0.00	6.86	2,994.86	0.00	516.53
14	360458	52336	9/27/2018	7/5/2027	12	DOLARES	CUOTA FIJA	MENSUAL	96	30	52,000.00	16,058.94	6.86	0.00	3,582.16	0.00
15	360466	48579	10/19/2018	11/19/2026	13	BOLIVIANOS	CUOTA FIJA	MENSUAL	99	30	105,000.00	32,165.60	6.86	13,811.29	0.00	8,655.57
16	360482	52706	11/14/2018	4/15/2029	13	BOLIVIANOS	CUOTA FIJA	MENSUAL	53	30	200,000.00	96,930.16	6.86	23,453.95	0.00	15,401.74
17	360486	48880	11/26/2018	12/9/2030	16	BOLIVIANOS	CUOTA FIJA	MENSUAL	60	30	70,000.00	40,235.30	6.86	8,904.67	0.00	6,555.81
18	360512	52976	2/1/2019	5/14/2031	12.95	BOLIVIANOS	CUOTA FIJA	MENSUAL	96	30	420,000.00	288,209.24	6.86	26,979.40	0.00	36,560.77
19	360515	50318	2/7/2019	12/10/2024	20	BOLIVIANOS	CUOTA FIJA	MENSUAL	60	30	32,000.00	0.00	6.86	893.38	0.00	831.93
20	360526	53751	2/27/2019	11/18/2025	22	BOLIVIANOS	CUOTA FIJA	MENSUAL	54	30	27,000.00	5,796.66	6.86	3,587.79	0.00	3,533.41

Los datos originales se pueden encontrar en el archivo llamado “Requerimiento_Externo_Cacef.xlsx” ubicado en la carpeta “Datos” en el CD proporcionado (Anexo Principal).

Anexo 2 Función de análisis univariado variables numéricas

```
def analiza_vars_numerica(df, var_list, bins=40):
    """
    Genera histogramas y boxplots para cada variable numérica en
    var_list,
    usando diferentes paletas de Seaborn para cada variable.
    """
    # Paletas de Seaborn que iremos rotando
    palettes = ['Blues', 'Greens', 'Reds', 'Purples', 'Oranges',
                'YlGnBu']

    total_vars = len(var_list)
    fig, axes = plt.subplots(nrows=total_vars, ncols=2, figsize=(10,
3*total_vars))

    for i, col in enumerate(var_list):
        # Selecciona la paleta según la posición i
        palette_name = palettes[i % len(palettes)]
        # Obtenemos 2 colores de esa paleta (uno para histograma y otro
para boxplot)
        color_list = sns.color_palette(palette_name, n_colors=2)
        hist_color = color_list[0]
        box_color = color_list[1]

        # Histograma con KDE
        sns.histplot(data=df, x=col, kde=True, bins=bins, ax=axes[i,0],
color=hist_color)
        axes[i,0].set_title(f"Histograma de {col}", fontsize=12)

        # Boxplot
        sns.boxplot(data=df, x=col, ax=axes[i,1], color=box_color)
        axes[i,1].set_title(f"Boxplot de {col}", fontsize=12)

    plt.tight_layout()
    plt.show()
```

Esta función puede encontrarse en el archivo “Proyecto Final, Cooperativa Cacefi.ipynb”, en la carpeta “Código” en el CD proporcionado (Anexo Principal).

Anexo 3 Función de análisis univariado variables categóricas

```
def analiza_vars_categorica(df, var_list):
    """
    Grafica la frecuencia (conteo de id_credito) por cada categoría en
    var_list,
    usando diferentes paletas para cada variable, con barras
    horizontales.
    """
    palettes = ['Blues', 'Greens', 'Reds', 'Purples', 'Oranges',
                'YlGnBu']

    total_vars = len(var_list)
    nrows = math.ceil(total_vars/2) # 2 gráficos por fila
    fig, axes = plt.subplots(nrows=nrows, ncols=2, figsize=(10, 3*nrows))
    axes = axes.flatten() # Para indexar fácilmente

    for i, col in enumerate(var_list):
        freq_data =
df.groupby(col) ['id_credito'].count().sort_values(ascending=True)

        # Selecciona la paleta
        palette_name = palettes[i % len(palettes)]
        # Tomamos un color del medio, por ejemplo
        color_list = sns.color_palette(palette_name, n_colors=5)
        bar_color = color_list[2]

        # Graficar en barras horizontales: barh(y=índice, x=valores)
        axes[i].barh(freq_data.index.astype(str), freq_data.values,
color=bar_color)
        axes[i].set_title(f"Conteo de id_credito por {col}", fontsize=12)

    # Ocultar ejes sobrantes si hay un número impar de variables
    if total_vars < len(axes):
        for j in range(total_vars, len(axes)):
            axes[j].set_visible(False)

    plt.tight_layout()
    plt.show()
```

Esta función puede encontrarse en el archivo “Proyecto Final, Cooperativa Cacef.ipynb”, en la carpeta “Código” en el CD proporcionado (Anexo Principal).

Anexo 4 Función de análisis bivariado variables numéricas

```
def analiza_num_bivariado(df, var_list, target='default'):
    """
    Genera, en una sola figura, un histograma (con hue=target) y un
    boxplot
    (x=target, y=variable) para cada variable numérica en var_list.
    Se organizan en 2 columnas fijas, y tantas filas como se requiera.
    """
    n = len(var_list)
    # 2 subplots por variable => total_subplots = 2 * n
    total_subplots = 2 * n
    # Paletas que rotaremos para el boxplot
    palettes = ['Accent', 'Paired', 'Pastell1', 'Set2', 'Set3', 'tab10',
'tab20']
    # 2 columnas => calculamos cuántas filas
    nrows = math.ceil(total_subplots / 2)
    fig, axes = plt.subplots(nrows, 2, figsize=(10, 4*nrows))
    axes = axes.flatten() # Array 1D de ejes
    idx = 0
    for col in var_list:
        # Boxplot
        if idx < total_subplots:
            palette_name = palettes[i % len(palettes)] # Ciclo de
paletas
            # Obtenemos 2-3 colores de esa paleta y elegimos uno
            color_list = sns.color_palette(palette_name, n_colors=nrows)
            box_color = color_list[idx]
            sns.boxplot(data=df, x=target, y=col, ax=axes[idx],
color=box_color)
            axes[idx].set_title(f"Boxplot: {col} vs. {target}")
            idx += 1

        # Ocultar ejes sobrantes (si sobran)
        for j in range(idx, len(axes)):
            axes[j].set_visible(False)

    plt.tight_layout()
    plt.show()
```

Esta función puede encontrarse en el archivo “Proyecto Final, Cooperativa Cacef.ipynb”, en la carpeta “Código” en el CD proporcionado (Anexo Principal).

Anexo 5 Función de análisis bivariado variables categóricas

```
def analiza_cat_bivariado(df, cat_list, target='default'):
    """
    Genera un 100% stacked bar horizontal para cada variable categórica
    en cat_list.
    """
    n = len(cat_list)
    nrows = math.ceil(n / 2)
    fig, axes = plt.subplots(nrows, 2, figsize=(12, 4*nrows))
    axes = axes.flatten()
    discrete_palettes = ['Accent', 'Paired', 'Pastell1', 'Set2', 'Set3',
'tab10', 'tab20']
    for i, cat_var in enumerate(cat_list):
        # Tabla de contingencia
        crosstab = pd.crosstab(df[cat_var], df[target])
        # Convertir a porcentaje (cada fila suma 100%)
        crosstab_perc = crosstab.div(crosstab.sum(axis=1), axis=0) * 100
        palette_name = discrete_palettes[i % len(discrete_palettes)]
        # Cantidad de clases en la variable objetivo
        n_clases = crosstab_perc.shape[1]
        # Creamos una lista de colores
        colors = sns.color_palette(palette_name, n_colors=n_clases)
        cmap = ListedColormap(colors)
        crosstab_perc.plot.barh(
            stacked=True,
            ax=axes[i],
            cmap=cmap
        )
        axes[i].set_xlabel("Porcentaje")
        axes[i].set_ylabel(cat_var)
        axes[i].set_title(f"Distribución de {target} por {cat_var}")
        axes[i].legend(title=target, bbox_to_anchor=(1.05, 1), loc='upper
left')
    if n < len(axes):
        for j in range(n, len(axes)):
            axes[j].set_visible(False)
    plt.tight_layout()
    plt.show()
```

Esta función puede encontrarse en el archivo “Proyecto Final, Cooperativa Cacef.ipynb”, en la carpeta “Código” en el CD proporcionado (Anexo Principal).

Anexo 6 QR del repositorio Github



Anexo principal y distribución de carpetas del CD

A continuación, se muestra el CD y la organización de las carpetas y archivos más importantes del proyecto.

